哈爾濱工業大學 海量数据计算研究中心
Massive Data Computing Lab @ HIT

大数据计算基础
第四章 大数据计算系统

王宏志

wangzh@hit.edu.cn
http://homepage.hit.edu.cn/pages/wang

目录

目录

什么是大数据的批处理？

- 批处理操作大容量静态数据集，并在计算过程完成后返回结果。
- 批处理模式中使用的数据集通常符合下列特征：
  - ✓ 有界：批处理数据集代表数据的有限集合。
  - ✓ 持久：数据通常始终存储在某种类型的持久存储位置中。
  - ✓ 大量：批处理操作通常是处理极为海量数据集的唯一方法。
- 批处理适合
  - 需要访问全套记录才能完成的计算工作
  - 对历史数据进行分析
- 批处理不适合
  - 对处理时间要求较高的场合

设计	工艺优化、流程优化、能效优化
供销	成本优化
销售	需求发现、产量预测
售后	备品供应

生产	质量监控、故障预测、生产状态监测
售后	产品运行状态监控、故障预警


Spark
Lightning-fast cluster computing

Spark的发展历程

- 2009：Spark诞生于伯克利大学 AMPLab
- 2010：开源
- 2013.6：Apache孵化器项目
- 2014.2：Apache顶级项目
- 目前为止，发布的最新版本为Spark1.4.1

Spark在最近6年内发展迅速，相较于其他大数据平台或框架而言，Spark的代码库最为活跃。

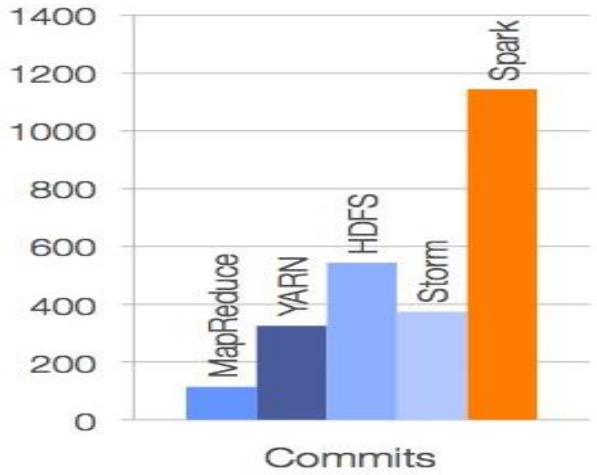

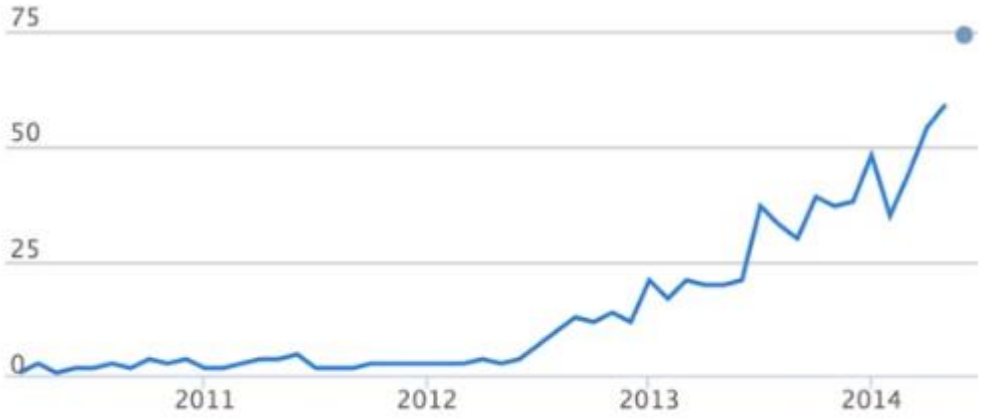

Spark代码贡献者每个月的增长曲线

截止2015年6月

- Spark的Contributor比2014年涨了3倍，达到730人；
- 总代码行数也比2014年涨了2倍多，达到40万行
- Spark应用也越来越广泛，最大的集群来自腾讯——8000个节点，单个Job最大分别是阿里巴巴和Databricks——1PB

http://spark.apache.org/

Spark的目标

- 为集群运算提供分布式内存抽象，以支持具有工作集的应用程序
- 保留了MapReduce的优秀特性：
  - 容错机制（为崩溃程序和落后程序）
  - 数据局部性
  - 可扩展性

解决方案： 使用“弹性分布式数据集”（RDDs）的增强数据流模型

Spark与Hadoop的对比

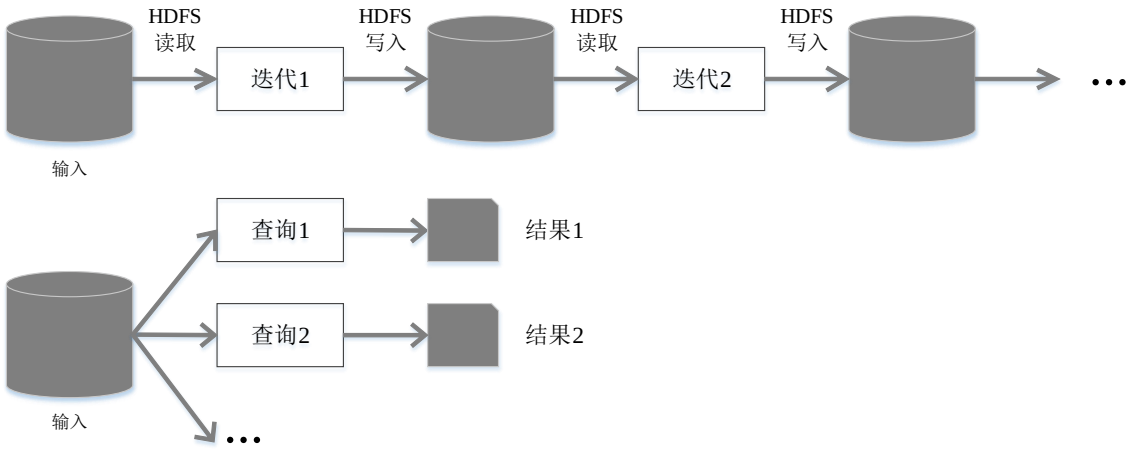

(a) Hadoop MapReduce执行流程

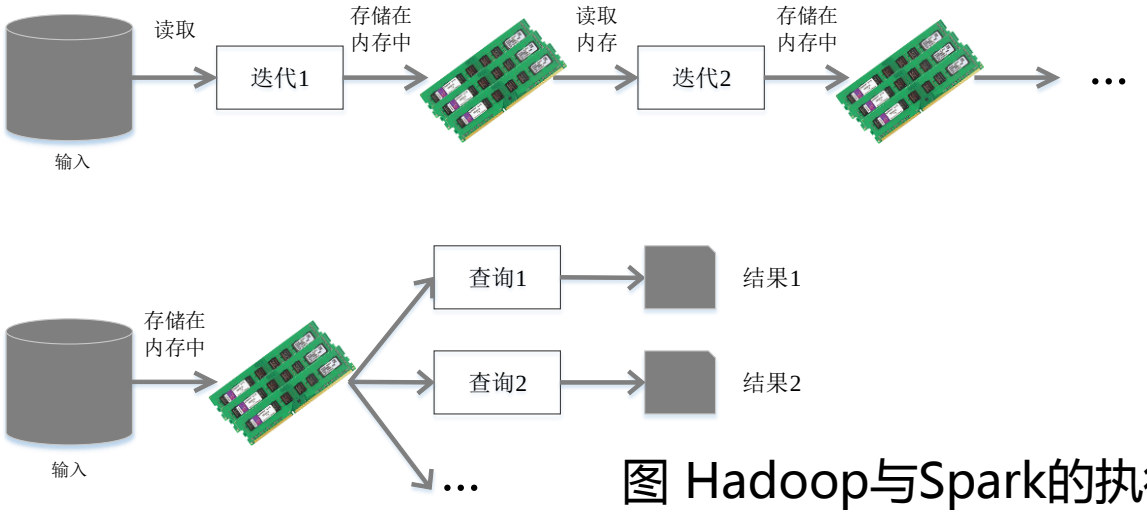

图 Hadoop与Spark的执行流程对比

(b) Spark执行流程

Hyracks

Hyracks简介

- UCI开发，2013年发布
- 并行数据计算平台，用于在使用share-nothing的大型集群对大量数据执行数据处理任务

概念区分

- share-nothing
- share-memory

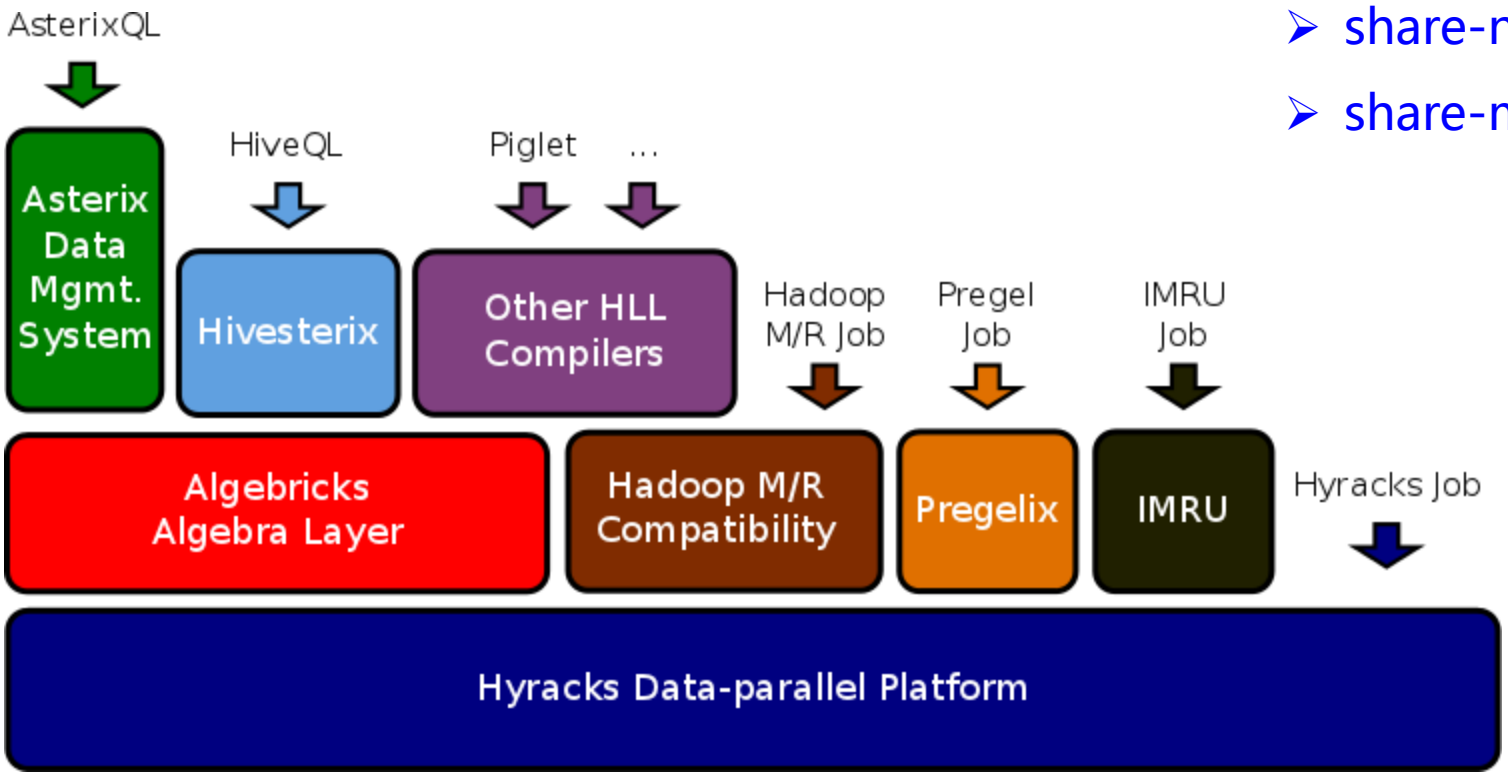

Hyracks开发的原因

- 数据总量成倍增长
  - 社交网络（Facebook：5亿活跃用户，每天超过5000万状态更新）
  - 网络：几万亿的链接
- 数据类型并不总是统一的
  - 半结构化数据
  - 结构化数据
  - 不同的数据模型（如数组等）
- 非传统的数据处理
  - 需要使用用户的逻辑来处理数据

比较Hyracks与其它平台

- VS. 并行数据库
  - 可扩展的数据模型
  - 容错机制
- VS. Hadoop
  - 更灵活的计算模型
  - 通用的运行时处理模型
  - 更好（透明）的支持调度

大数据的批处理任务的抽象

需要解决的问题

- 操作的数据形式和结构是什么？
- 应用程序可以对于数据做何种操作？

需要考虑的问题

- 适用的场景/数据是什么？
- 面向的软硬件环境是什么？
- 和支撑应用程序之间的界面在哪里？


Spark
Lightning-fast cluster computing

RDD设计背景

- 许多迭代式（比如机器学习、图算法等）和交互式数据挖掘工具，共同之处是，不同计算阶段之间会重用中间结果
- 目前的MapReduce框架都是把中间结果写入到稳定存储（比如磁盘）中，带来了大量的数据复制、磁盘IO和序列化开销
- RDD提供了一个抽象的数据架构，不必担心底层数据的分布式特性，只需将具体的应用逻辑表达为一系列转换处理
- 不同RDD之间的转换操作形成依赖关系，可以实现数据流水处理，避免中间数据存储

概念区分

- 流水 (pipeline)
- 阻塞 (blocked)

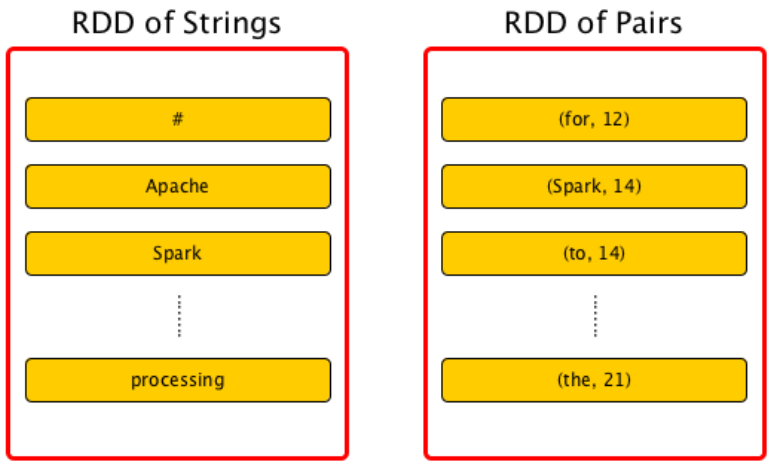

RDD概念

- 一个RDD是一个分布式对象集合，本质上是一个只读的分区记录集合
- 每个RDD可分成多个分区，每个分区就是一个数据集片段
- 一个RDD的不同分区可以被保存到集群中不同的节点上，从而可以在集群中的不同节点上进行并行计算
- RDD提供了一种高度受限的共享内存模型
  - ✓ RDD是只读的记录分区的集合，不能直接修改
  - ✓ 只能基于稳定的物理存储中的数据集创建RDD，或者通过在其他RDD上执行确定的转换操作（如map、join和group by）而创建得到新的RDD

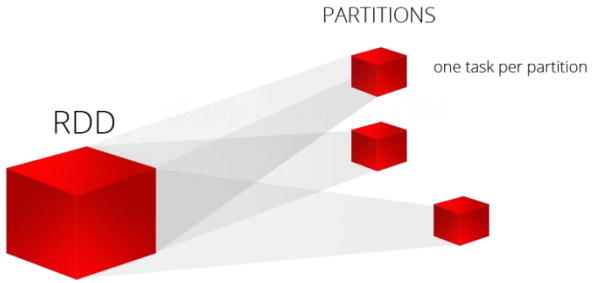

RDD的操作

- RDD提供了一组丰富的操作以支持常见的数据运算，分为“动作”（Action）和“转换”（Transformation）两种类型
- RDD提供的转换接口都非常简单，都是类似map、filter、groupBy、join等粗粒度的数据转换操作，而不是针对某个数据项的细粒度修改（不适合网页爬虫）
- RDD已经被实践证明可以高效地表达许多框架的编程模型（如MapReduce、SQL、Pregel）
- Spark用Scala语言实现了RDD的API，程序员可以通过调用API实现对RDD的各种操作

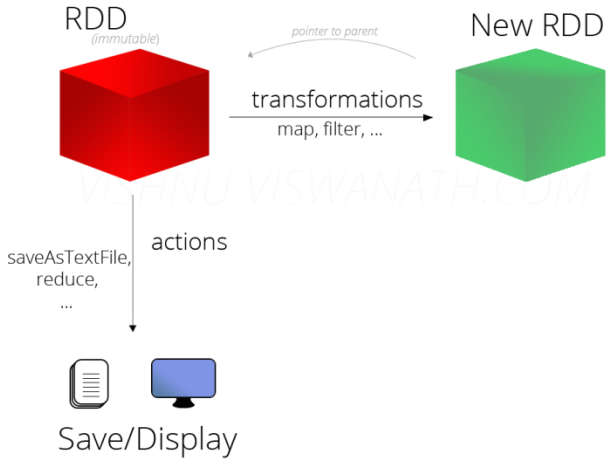

RDD的执行过程

- RDD读入外部数据源进行创建
- RDD经过一系列的转换（Transformation）操作，每一次都会产生不同的RDD，供给下一个转换操作使用
- 最后一个RDD经过“动作”操作进行转换，并输出到外部数据源

这一系列处理称为一个Lineage（血缘关系），即DAG拓扑排序的结果

优点：惰性调用、管道化、避免同步等待、不需要保存中间结果、每次操作变得简单

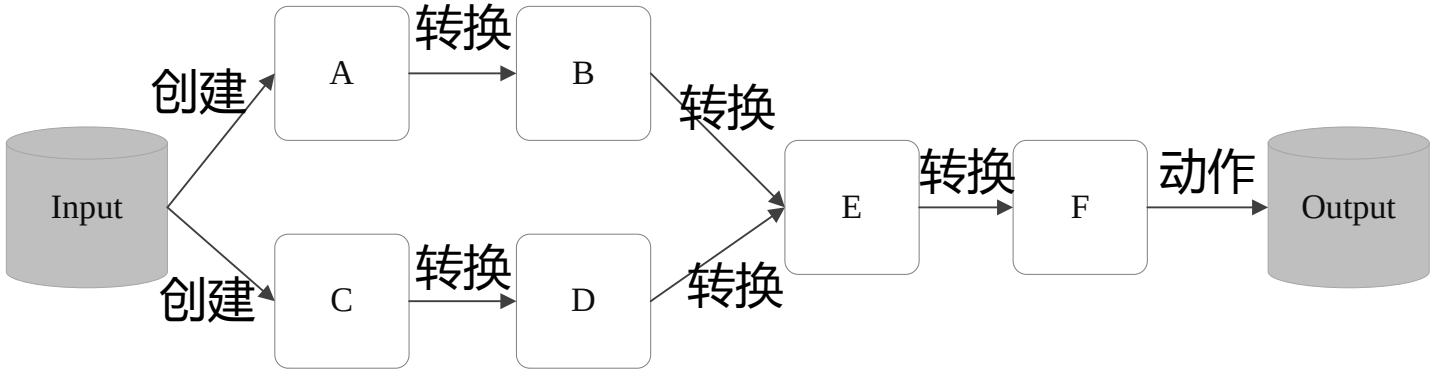

RDD高效的原因

- 高效的容错性
  - ✓ 现有容错机制：数据复制或者记录日志
  - ✓ RDD：血缘关系、重新计算丢失分区、无需回滚系统、重算过程在不同节点之间并行、只记录粗粒度的操作
- 中间结果持久化到内存，数据在内存中的多个RDD操作之间进行传递，避免了不必要的读写磁盘开销
- 存放的数据可以是Java对象，避免了不必要的对象序列化和反序列化

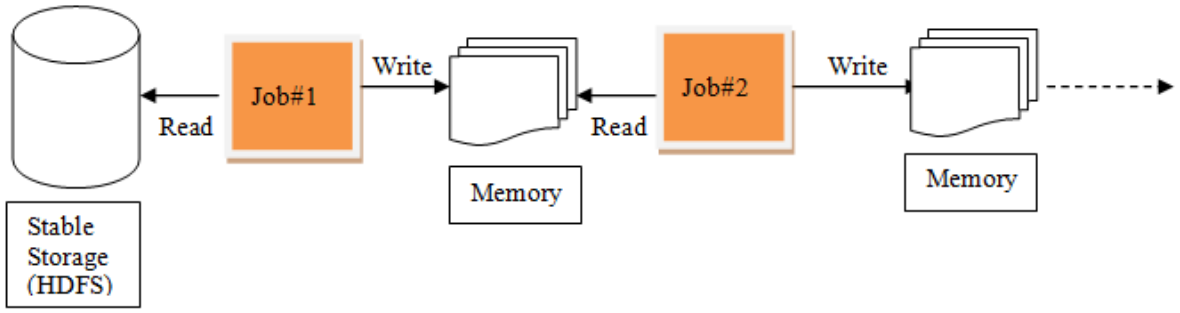

Hyracks

Hyracks 的数据对象

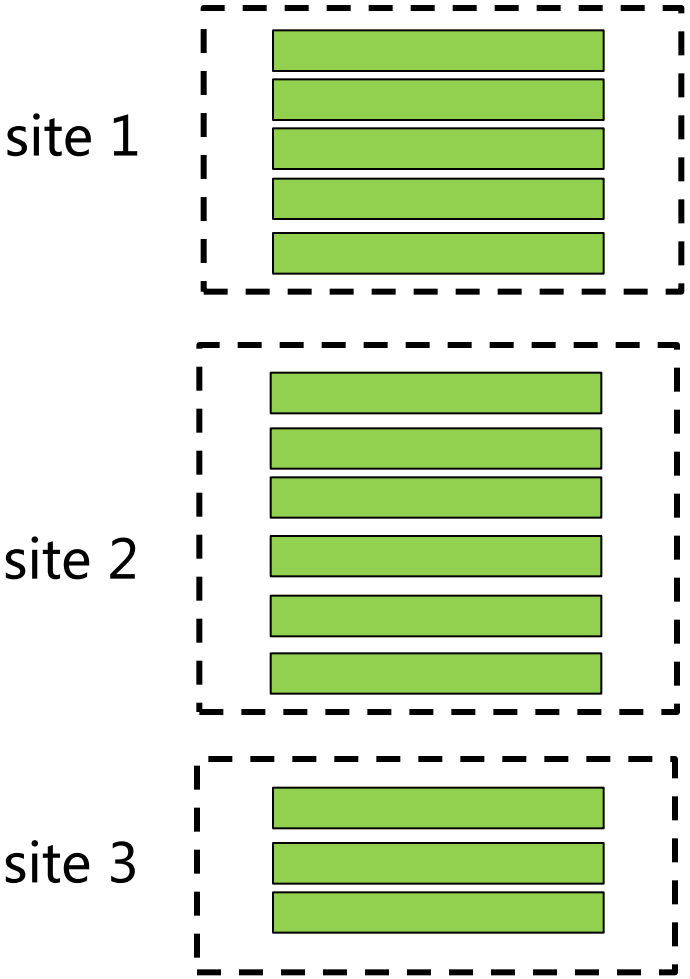

- 在N个站点分区的记录
- 存储有模式的记录（不仅仅是key-value）

数据对象上的操作

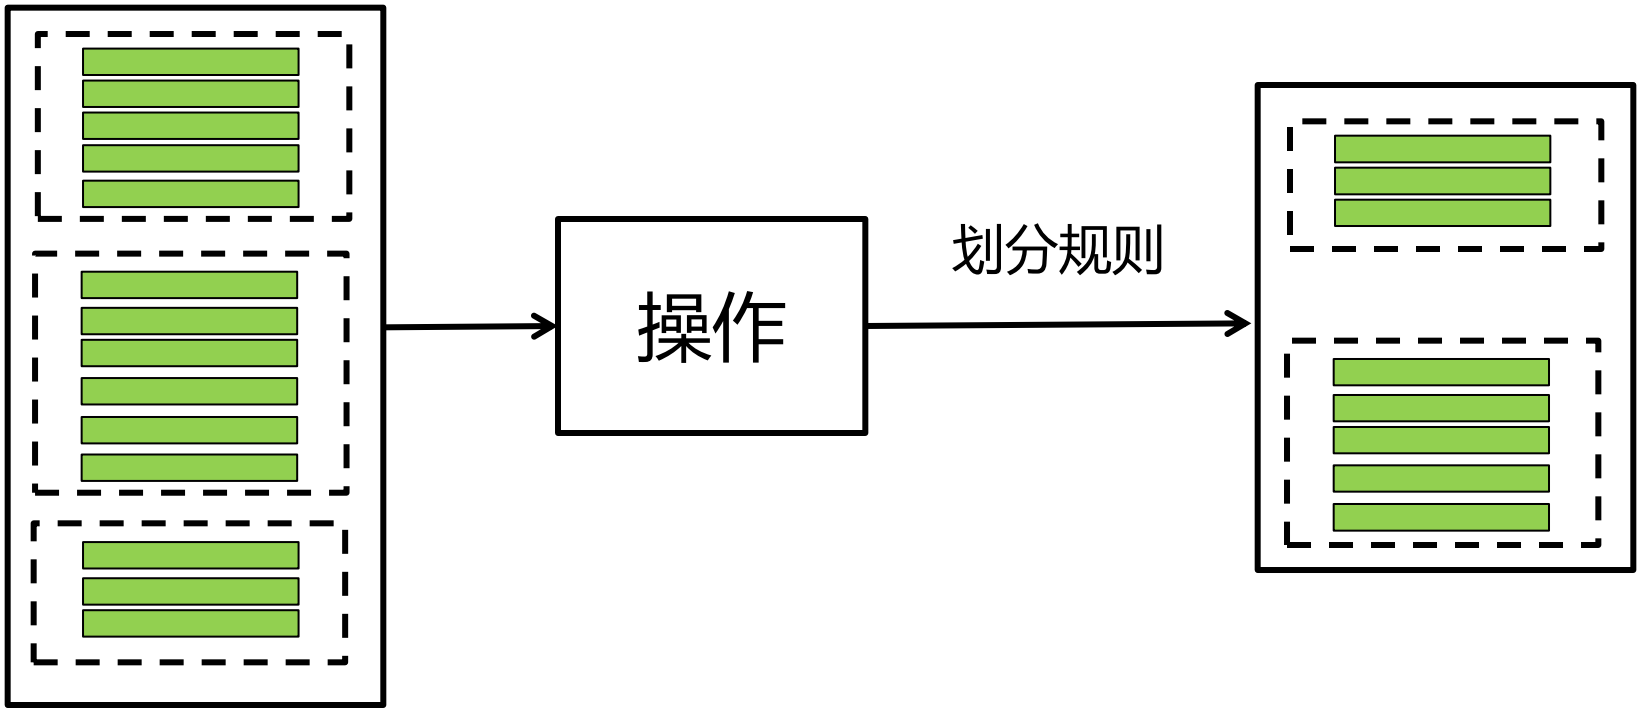

操作的并行处理

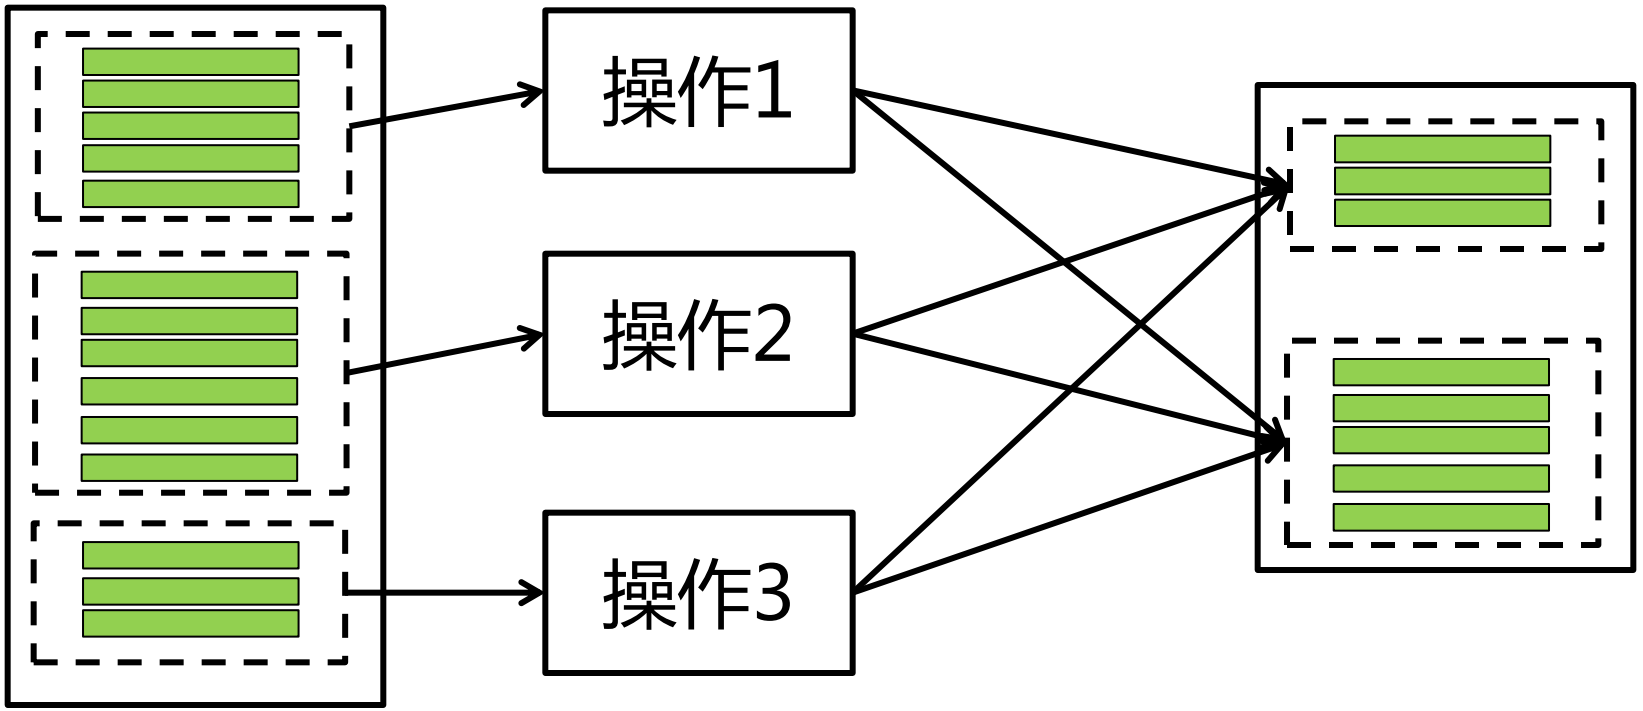

大数据的批处理框架的API

需要解决的问题

- 程序员如何基于框架编写应用程序？

需要考虑的问题

- 面向什么样的程序员？
- 开发的效率？
- 程序的易读性？
- 程序的美感？
- 是否符合传统开发的习惯？


Spark
Lightning-fast cluster computing

Spark编程模型

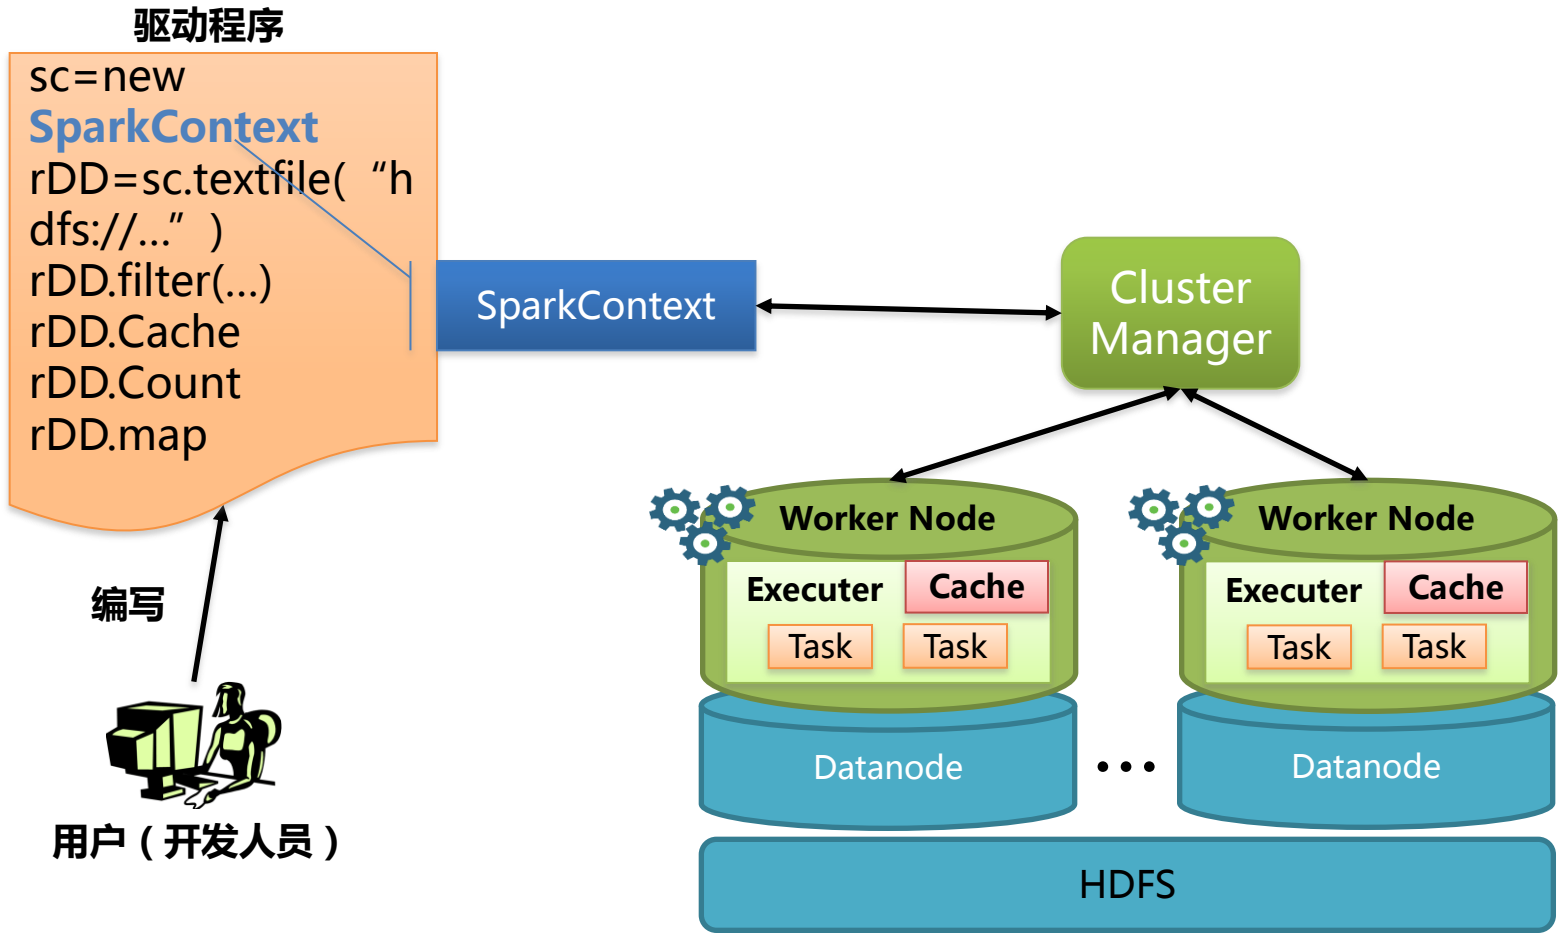
驱动程序
sc=new SparkContext
rDD=sc.textfile(“hdfs://…”)
rDD.filter(…)
rDD.Cache
rDD.Count
rDD.map
SparkContext
Cluster Manager
Worker Node
Executer
Cache
Task
Task
Worker Node
Executer
Cache
Task
Task
Datanode
Datanode
HDFS
编写
用户（开发人员）

Spark编程模型

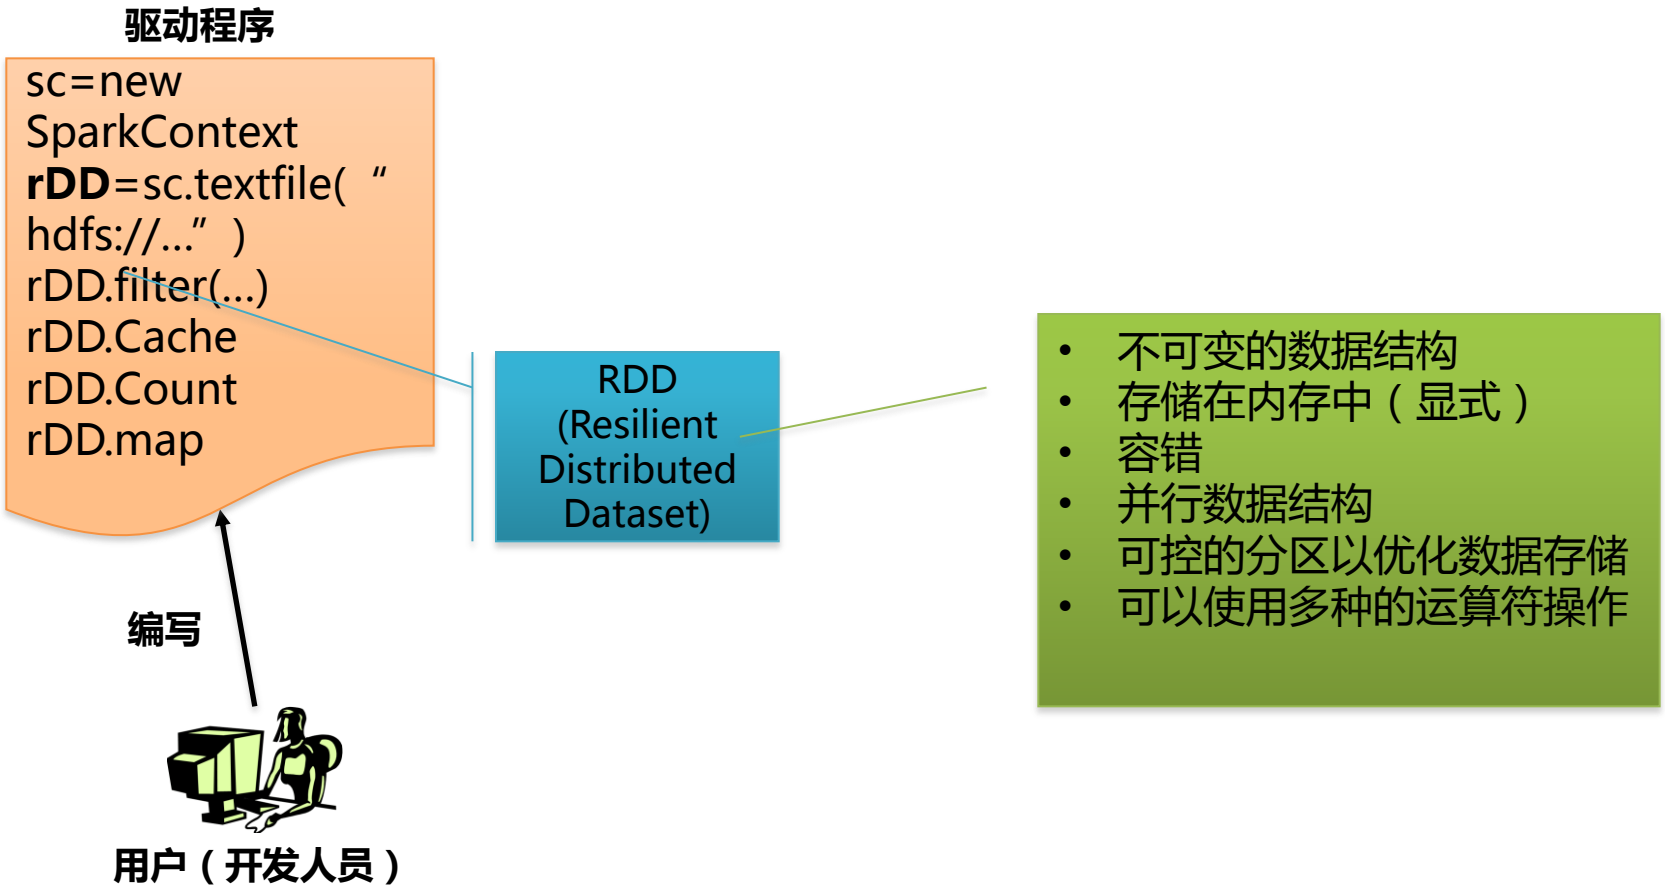
驱动程序
sc=new SparkContext
rDD=sc.textfile(“hdfs://…”)
rDD.filter(…)
rDD.Cache
rDD.Count
rDD.map
RDD (Resilient Distributed Dataset)
不可变的数据结构
存储在内存中（显式）
容错
并行数据结构
可控的分区以优化数据存储
可以使用多种的运算符操作
编写
用户（开发人员）

操作RDD的API

- 编程接口：程序员可以执行3种类型的操作

Transformations

•从现有的数据集中创建新的数据集.

•惰性计算。它们仅在action执行时才执行。

•例子：
- Map(func)
- Filter(func)
- Distinct()

Actions

•返回一个数据到驱动程序或者计算之后向一个存储系统输出数据

•例子:
- Count()
- Reduce(funct)
- Collect
- Take()

Persistence

•为后续操作在内存中缓存数据集

•可选存在磁盘上或者RAM上，或混合存储（存储级别）

•例子:
- Persist()
- Cache()

例1：日志挖掘

- 从日志中加载错误信息到内存，接着交互式地搜索不同的模式

```
lines = spark.textFile(“hdfs://...”)
errors = lines.filter(_.startsWith(“ERROR”))
messages = errors.map(_.split(‘\t’)(2))
cachedMsgs = messages.cache()

cachedMsgs.filter(_.contains(“foo”)).count
cachedMsgs.filter(_.contains(“bar”)).count
. . .
```

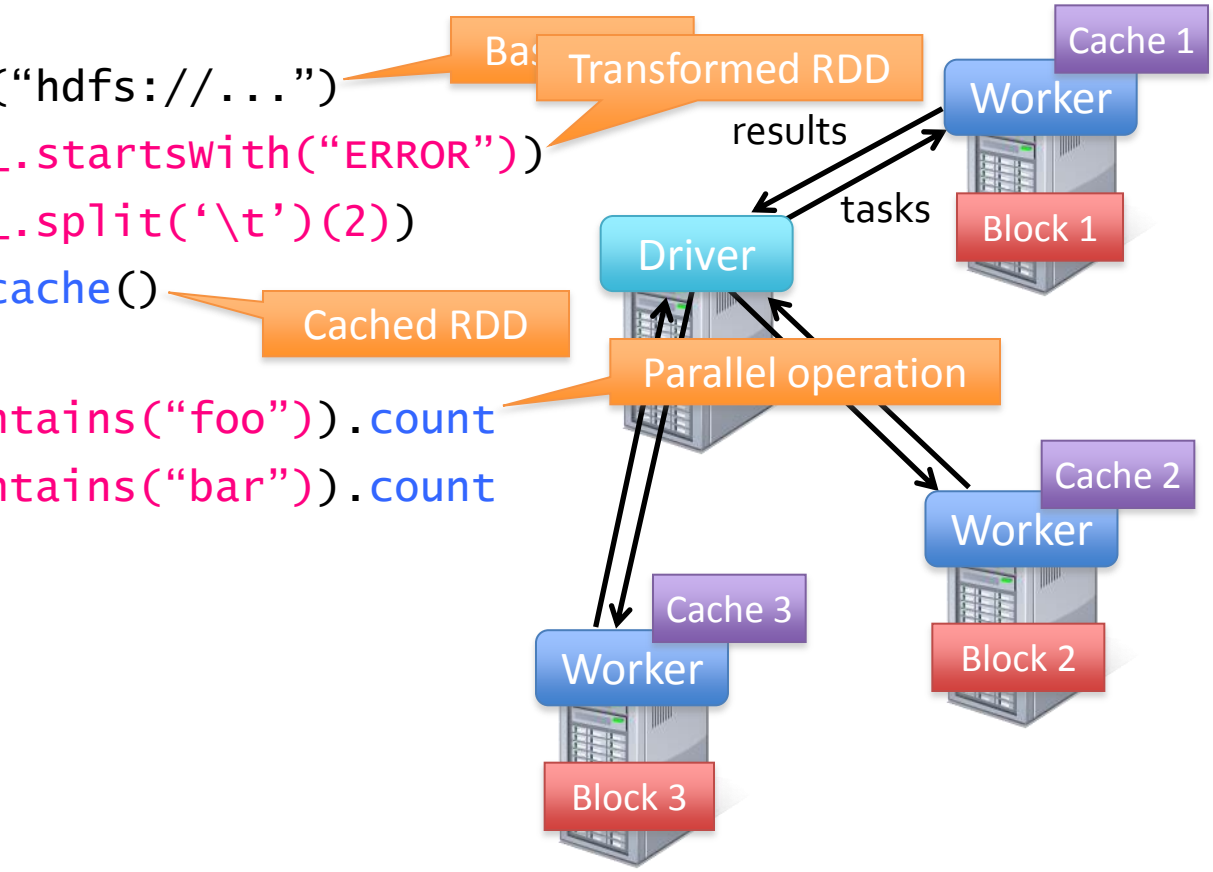

例2：逻辑回归

- 目的：找到最好的分割两组点的直线

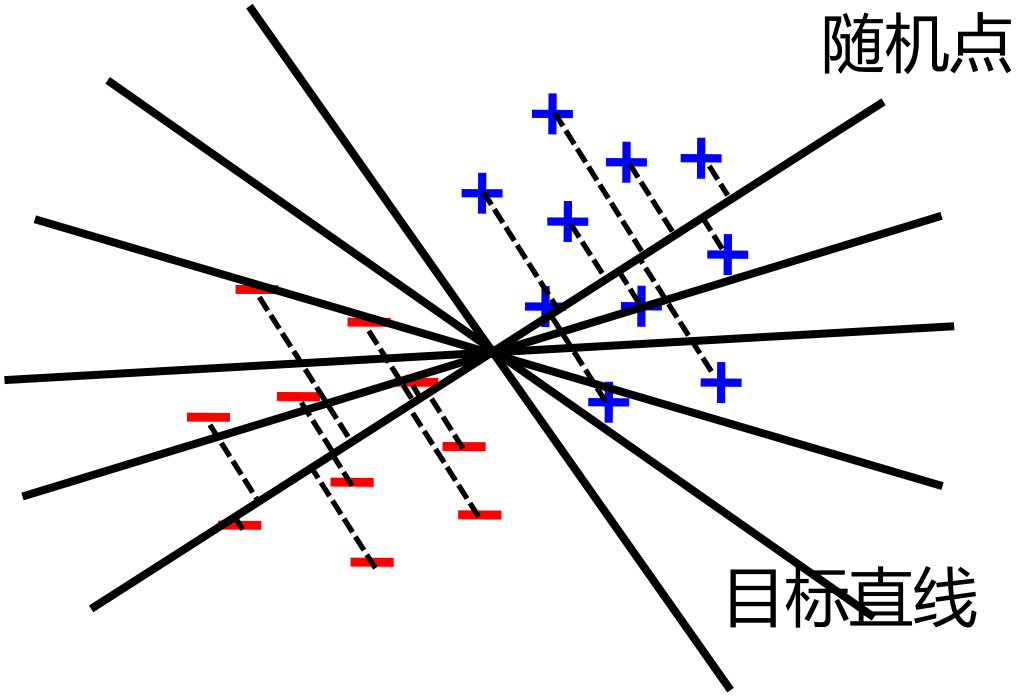

逻辑回归代码

```
val data = spark.textFile(...).map(readPoint).cache()

var w = Vector.random(D)

for (i <- 1 to ITERATIONS) {
 val gradient = data.map(p =>
   (1 / (1 + exp(-p.y*(w dot p.x))) - 1) * p.y * p.x
 ).reduce(_ + _)
 w -= gradient
}

println("Final w: " + w)
```

例3：MapReduce

MapReduce可以用RDD转换来表示

```
res = data.flatMap(rec => myMapFunc(rec))
        .groupByKey()
        .map((key, vals) => myReduceFunc(key, vals))
```

或者使用Combiner

```
res = data.flatMap(rec => myMapFunc(rec))
        .reduceByKey(myCombiner)
        .map((key, val) => myReduceFunc(key, val))
```

例4：字数统计

```
public class WordCount {
  public static class TokenizerMapper
       extends Mapper<Object, Text, Text, IntWritable>{

    private final static IntWritable one = new IntWritable(1);
    private Text word = new Text();

    public void map(Object key, Text value, Context context
                    ) throws IOException, InterruptedException {
      StringTokenizer itr = new StringTokenizer(value.toString());
      while (itr.hasMoreTokens()) {
        word.set(itr.nextToken());
        context.write(word, one);
      }
    }
  }

  public static class IntSumReducer
       extends Reducer<Text,IntWritable,Text,IntWritable> {
    private IntWritable result = new IntWritable();

    public void reduce(Text key, Iterable<IntWritable> values,
                       Context context
                       ) throws IOException, InterruptedException {
      int sum = 0;
      for (IntWritable val : values) {
        sum += val.get();
      }
      result.set(sum);
      context.write(key, result);
    }
  }

  public static void main(String[] args) throws Exception {
    Configuration conf = new Configuration();
    String[] otherArgs = new GenericOptionsParser(conf, args).getRemainingArgs();
    if (otherArgs.length < 2) {
      System.err.println("Usage: wordcount <in> [<in>...] <out>");
      System.exit(2);
    }
    Job job = new Job(conf, "word count");
    job.setJarByClass(WordCount.class);
    job.setMapperClass(TokenizerMapper.class);
    job.setCombinerClass(IntSumReducer.class);
    job.setReducerClass(IntSumReducer.class);
    job.setOutputKeyClass(Text.class);
    job.setOutputValueClass(IntWritable.class);
    for (int i = 0; i < otherArgs.length - 1; ++i) {
      FileInputFormat.addInputPath(job, new Path(otherArgs[i]));
    }
    FileOutputFormat.setOutputPath(job,
      new Path(otherArgs[otherArgs.length - 1]));
    System.exit(job.waitForCompletion(true) ? 0 : 1);
  }
}
```

WordCount in 50+ lines of Java MR

```
val f = sc.textFile(inputPath)
val w = f.flatMap(l => l.split(" ")).map(word => (word, 1)).cache()
w.reduceByKey(_ + _).saveAsText(outputPath)
```

WordCount in 3 lines of Spark

字数统计的代码

Scala:

```
val f = sc.textFile("README.md")
val wc = f.flatMap(l => l.split(" ")).map(word => (word, 1)).reduceByKey(_ + _)
wc.saveAsTextFile("wc_out")
```

Python:

```
from operator import add
f = sc.textFile("README.md")
wc = f.flatMap(lambda x: x.split(' ')).map(lambda x: (x, 1)).reduceByKey(add)
wc.saveAsTextFile("wc_out")
```

Hyracks

Hyracks – 使用场景

- 设计时考虑了三种可能的用途
  - ✓以高级数据语言为编译目标
    - ➢直接编译为原生Hyracks工程
    - ➢编译Hadoop工程并使用兼容层运行
  - ✓从现有的Hadoop客户端运行Hadoop工程
  - ✓运行原生的Hyracks工程

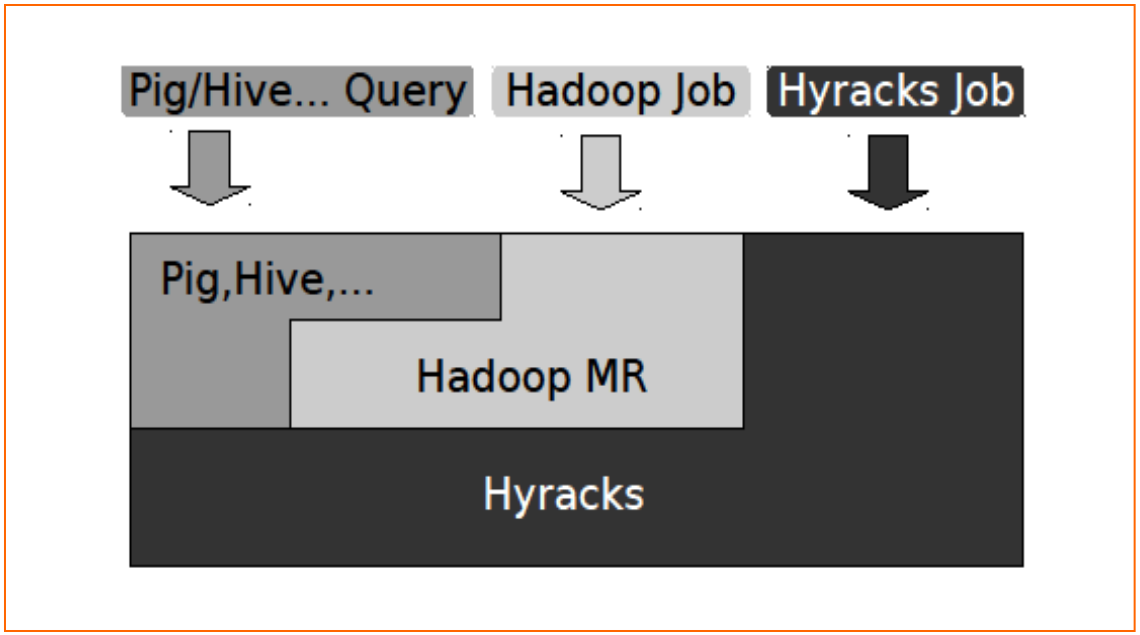

Hyracks操作/连接接口

- 接受ByteBuffer对象的统一的push-style迭代器接口

```
public interface IFrameWriter {
        public void open() …;
        public void close() …;
        public void nextFrame(ByteBuffer frame)…;
}
```

- 操作可以被连接在同一个线程或是不同的线程中运行
- 直接调用/改写底层操作

大数据的批处理系统的系统架构

需要解决的问题

- 系统有哪些模块？
- 模块之间如何交互？

需要考虑的问题

- 有效配合硬件
- 扩展性高
- 效率高
- 弹性好
- 开发容易
- 维护方便
- 升级简单


Spark
Lightning-fast cluster computing

基本概念

- DAG：是Directed Acyclic Graph（有向无环图）的简称，反映RDD之间的依赖关系
- Executor：是运行在工作节点（WorkerNode）的一个进程，负责运行Task
- 应用（Application）：用户编写的Spark应用程序
- 任务（ Task ）：运行在Executor上的工作单元
- 作业（ Job ）：一个作业包含多个RDD及作用于相应RDD上的各种操作
- 阶段（ Stage ）：是作业的基本调度单位，一个作业会分为多组任务，每组任务被称为阶段，或者也被称为任务集合，代表了一组关联的、相互之间没有Shuffle依赖关系的任务组成的任务集

架构设计

- Spark运行架构包括集群资源管理器（Cluster Manager）、运行作业任务的工作节点（Worker Node）、每个应用的任务控制节点（Driver）和每个工作节点上负责具体任务的执行进程（Executor）
- 资源管理器可以自带或Mesos或YARN

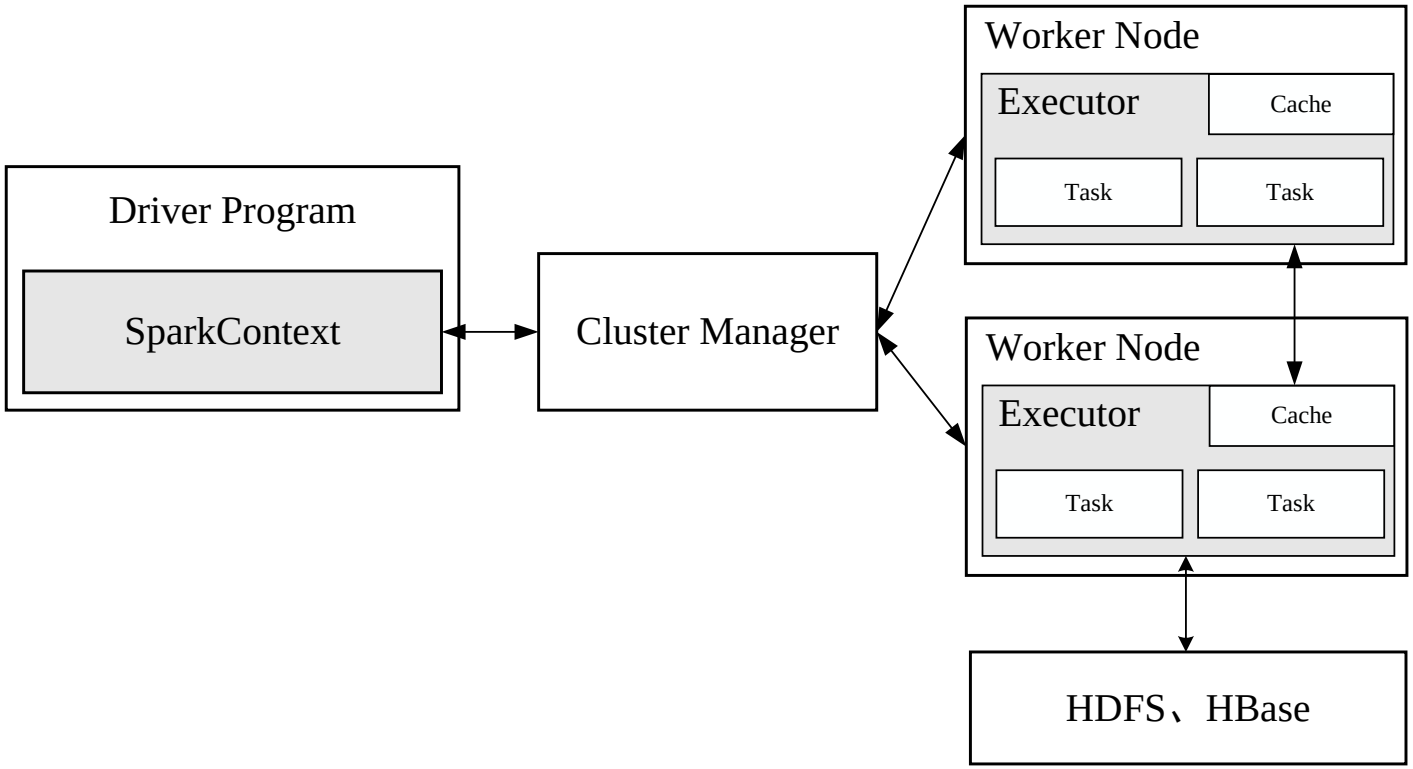

SparkContext

SparkContext处于DriverProgram核心位置，所有与Cluster、Worker Node交互的操作都需要SparkContext来完成

```
val sc = new SparkContext(master="local[*]",
            appName="SparkMe App", new SparkConf)

val lines = sc.textFile(...).cache()

val c = lines.count()
println(s"There are $c lines in $fileName")
```

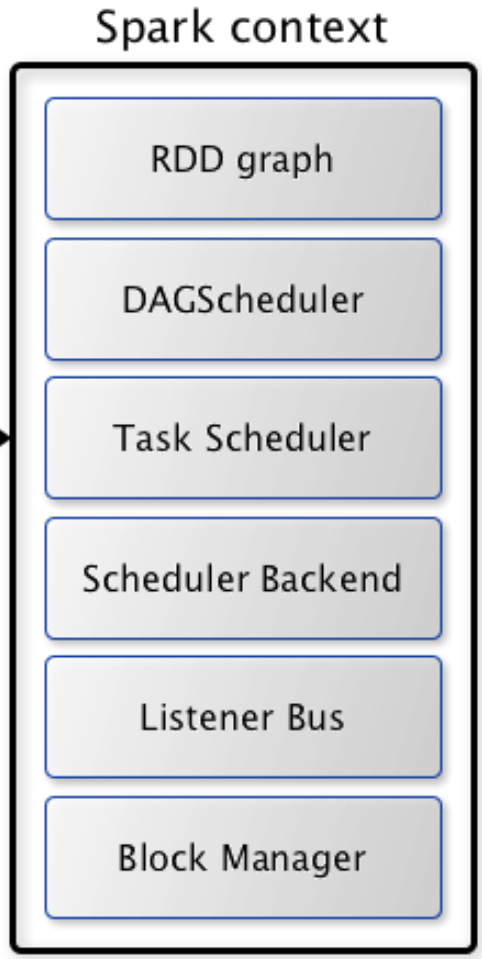

架构设计

- 一个应用由一个Driver和若干个作业构成，一个作业由多个阶段构成，一个阶段由多个没有Shuffle关系的任务组成
- 当执行一个应用时，Driver会向集群管理器申请资源，启动Executor，并向Executor发送应用程序代码和文件，然后在Executor上执行任务，运行结束后，执行结果会返回给Driver，或者写到HDFS或者其他数据库中

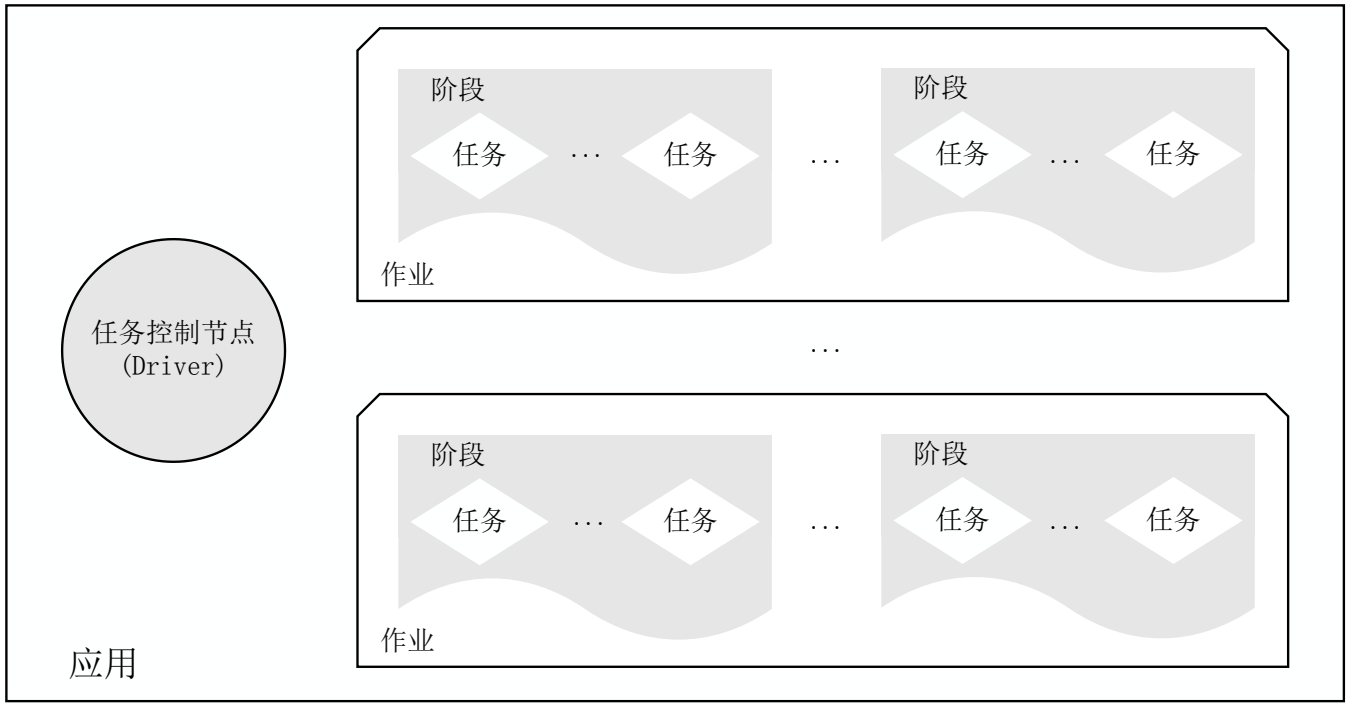

Hyracks

Hyracks的结构

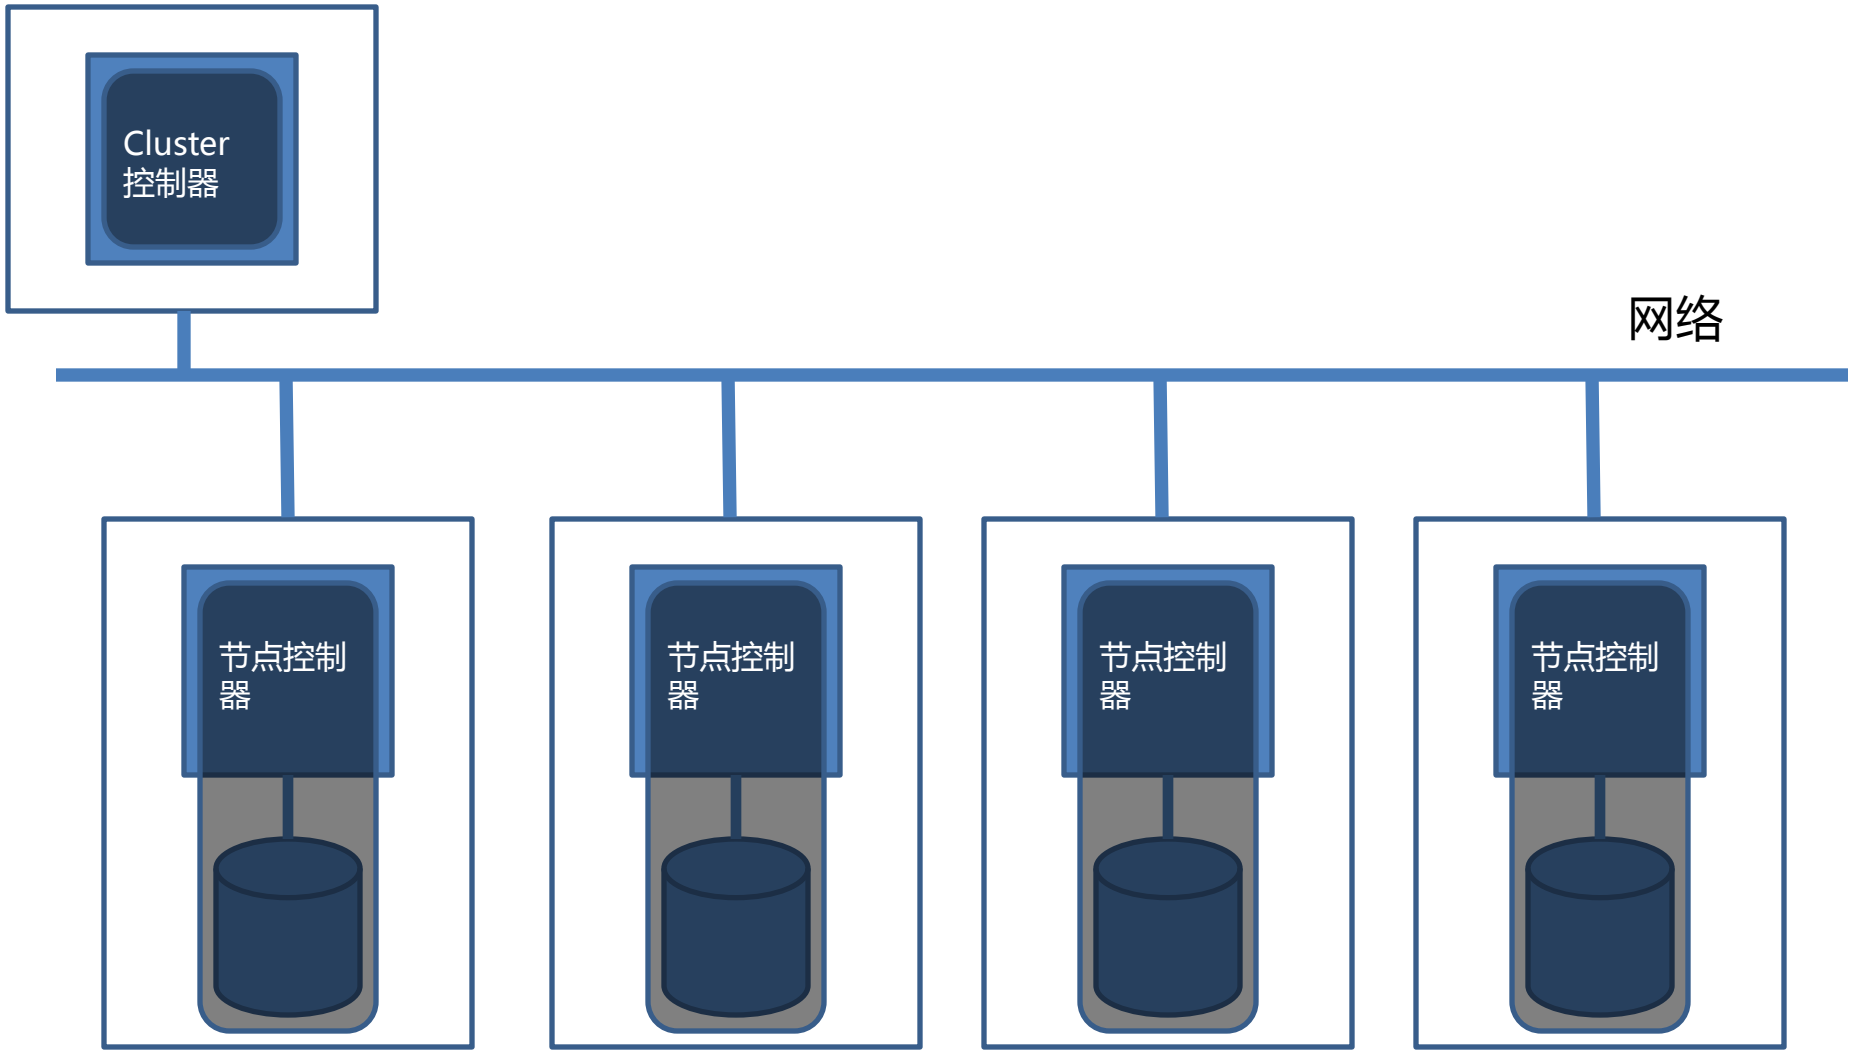

大数据的批处理系统的基本数据操作

需要解决的问题

- 包括哪些基本数据操作？
- 并行还是串行实现？
- 高效实现算法？

需要考虑的问题

- 有效支撑API
- 容易理解
- 扩展性高
- 效率高


Spark
Lightning-fast cluster computing

Shuffle操作

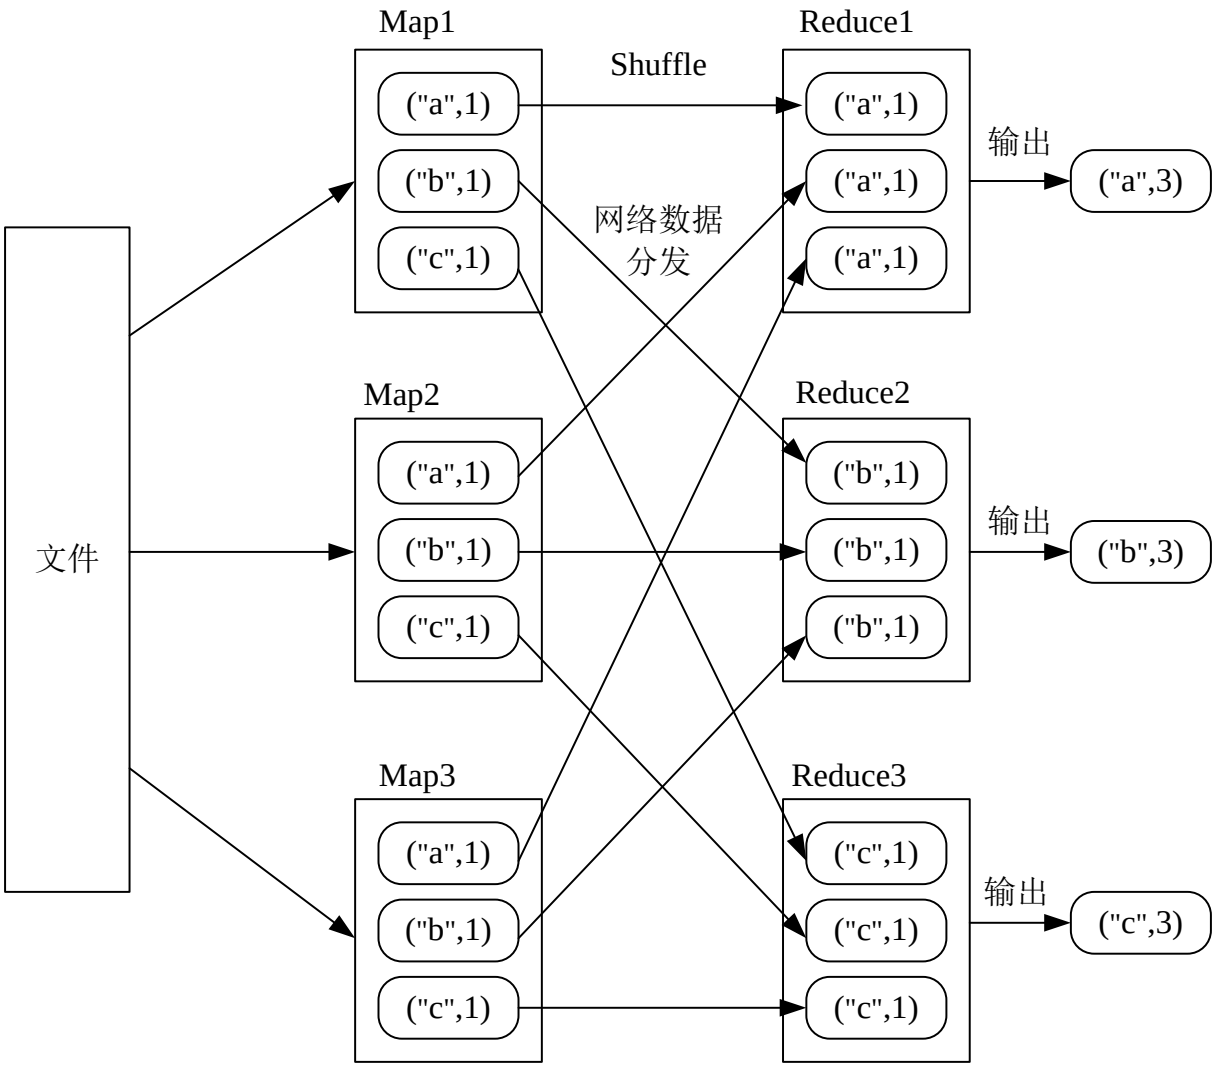
Map1
Shuffle
Reduce1
("a",1)
("b",1)
("c",1)
("a",1)
("a",1)
("a",1)
输出
("a",3)
网络数据
分发
Map2
Reduce2
("a",1)
("b",1)
("c",1)
("b",1)
("b",1)
("b",1)
输出
("b",3)
文件
Map3
Reduce3
("a",1)
("b",1)
("c",1)
("c",1)
("c",1)
("c",1)
输出
("c",3)

窄依赖和宽依赖

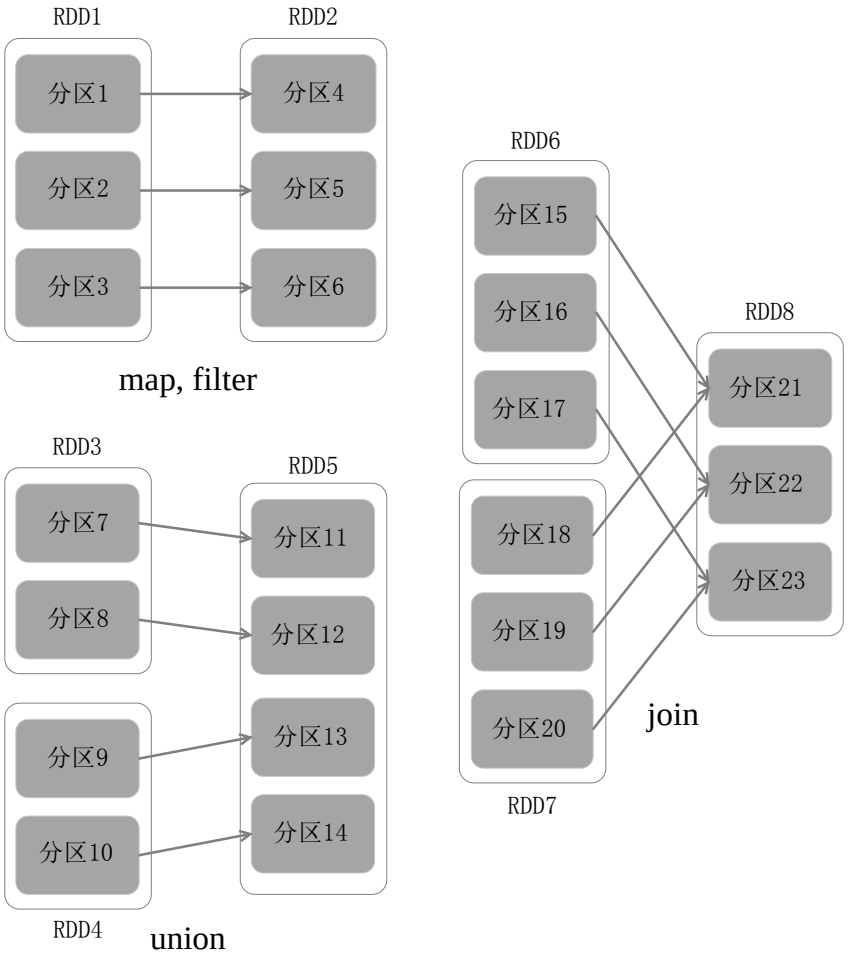

(a)窄依赖

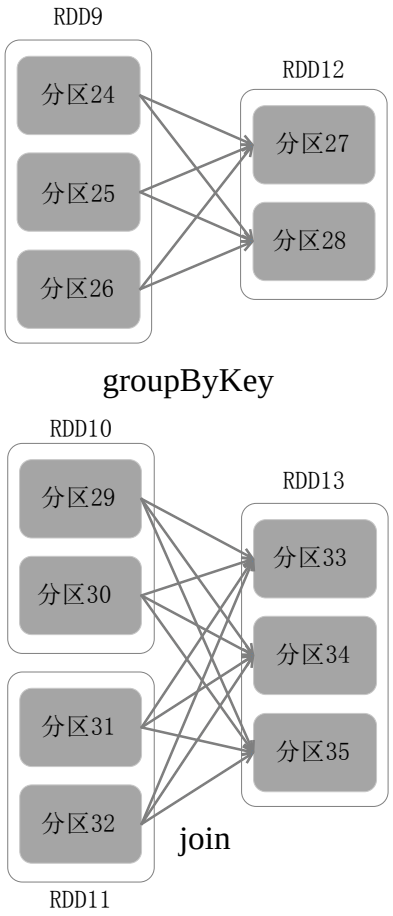

(b)宽依赖

- ✓ 窄依赖：一个父RDD的分区对应于一个子RDD的分区或多个父RDD的分区对应于一个子RDD的分区
- ✓ 宽依赖：存在一个父RDD的一个分区对应一个子RDD的多个分区

Hyracks

Hyracks操作/连接设计

- 对抽象数据类型的集合的操作
- 实例化期间提供数据模型操作
- 如：
  - 排序操作接受一系列比较操作
  - 基于散列的分组操作接受一系列散列方法和比较操作
  - 散列分区的连接接受散列方法

操作库

- File reader/writers
- Mappers
- Sorters
- Joiners (各种类型)
- Aggregators

- 更多...

连接库

- N:M 哈希划分
- N:M 哈希划分合并 (输入有序)
- N:M 分区划分(使用分区向量)
- N:M 复制
- 1:1

- 更多...

Hyracks数据移动

- 修复用以传输数据的内存块
- 用于迭代序列化数据的游标
- 普通的操作（比较/散列/映射）可以直接在框架中规定数据上执行
- 目的：最小化垃圾回收次数以及最小化数据副本
  - 有趣的是：执行约60分钟的请求，总的GC时间约为1.8秒。

大数据的批处理系统中的流程生成

需要解决的问题

- 基本数据操作和用户自定义逻辑的步骤划分
- 基本数据操作和用户自定义逻辑的执行顺序

需要考虑的问题

- 可用性高
- 效率高
- 容易理解
- 容易支持调试工具


Spark
Lightning-fast cluster computing

阶段的划分

- 根据DAG 图中的RDD 依赖关系，把一个作业分成多个阶段。
- 阶段划分的依据是窄依赖和宽依赖：窄依赖对于作业的优化很有利，宽依赖无法优化
- 逻辑上，每个RDD 操作都是一个fork/join（一种用于并行执行任务的框架），把计算fork 到每个RDD 分区，完成计算后对各个分区得到的结果进行join 操作，然后fork/join 下一个RDD 操作

- ✓ 窄依赖：一个父RDD的分区对应于一个子RDD的分区或多个父RDD的分区对应于一个子RDD的分区
- ✓ 宽依赖：存在一个父RDD的一个分区对应一个子RDD的多个分区

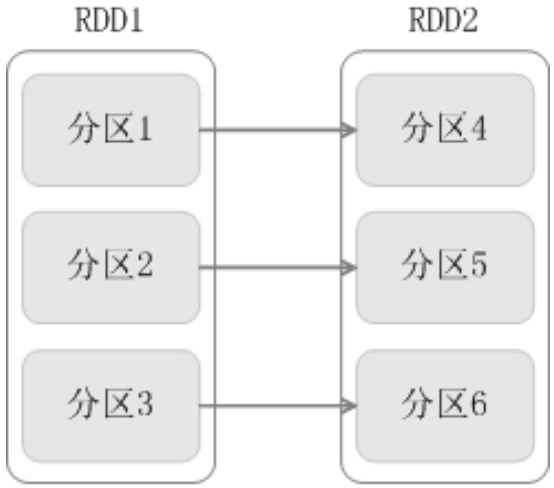

map, filter

fork/join的优化原理

举例：一个学校（含2个班级）完成从北京到厦门的旅行

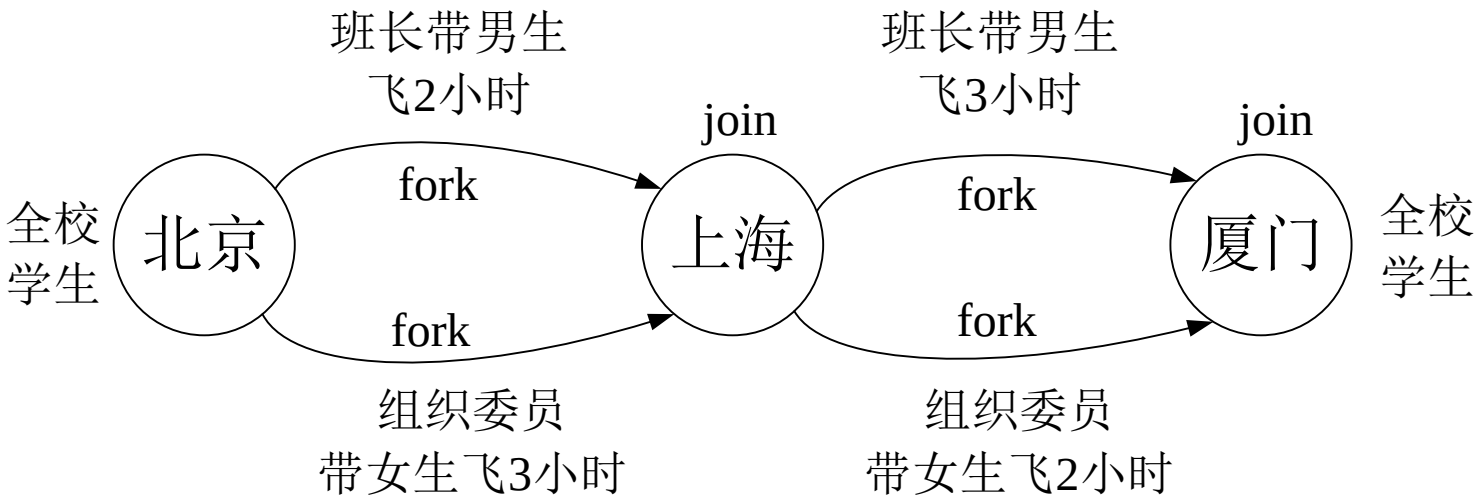

阶段的划分

宽依赖往往对应着shuffle操作(多对一,汇总,多节点)，需要在运行过程中将同一个父RDD的分区传入到不同的子RDD分区中，中间可能涉及多个节点之间的数据传输；而窄依赖的每个父RDD的分区只会传入到一个子RDD分区中，通常可以在一个节点内完成转换

窄依赖可以实现“流水线”优化

宽依赖无法实现“流水线”优化

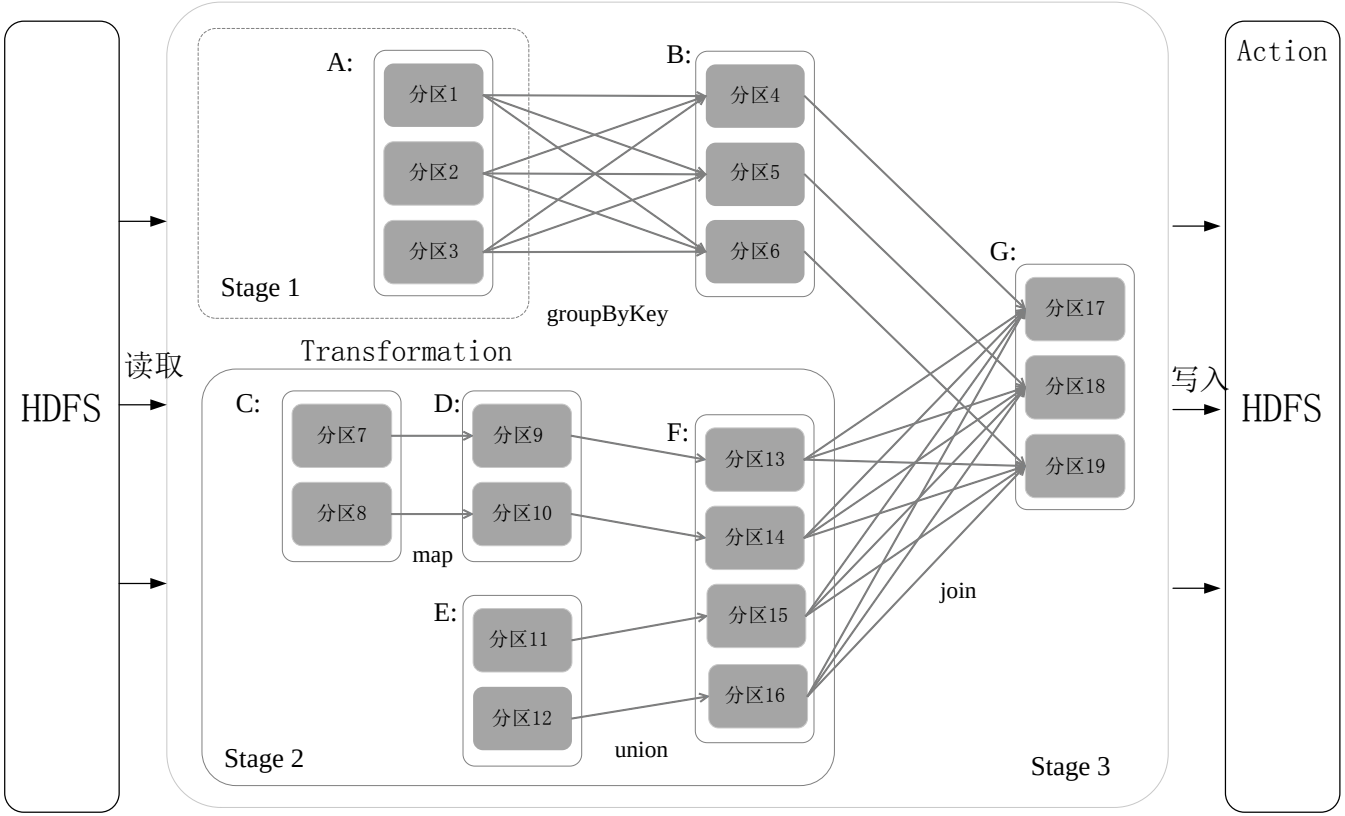

阶段的划分

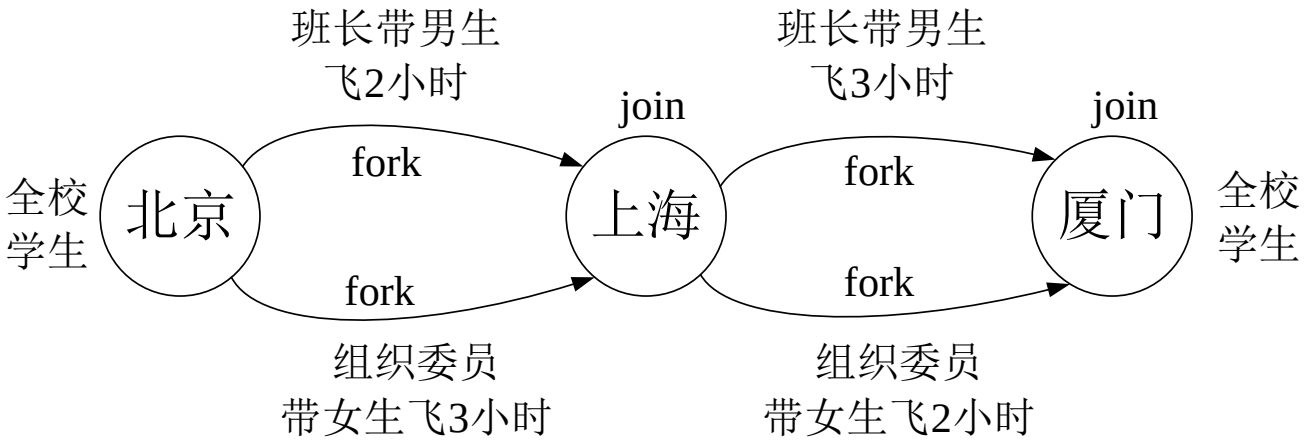

（a）窄依赖

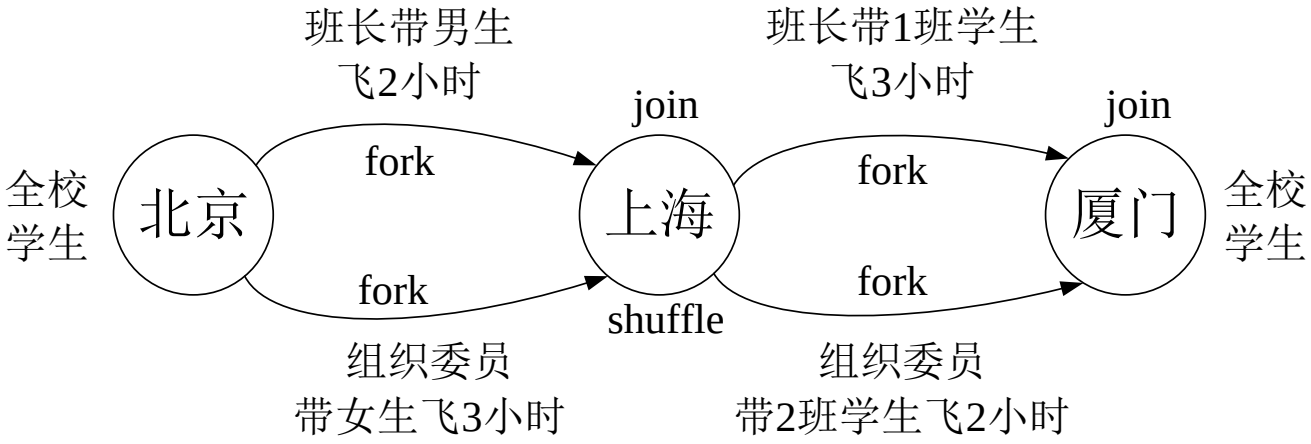

（a）宽依赖

划分的方法

- 通过分析各个RDD的依赖关系生成了DAG，再通过分析各个RDD中的分区之间的依赖关系来决定如何划分Stage
- 具体步骤(贪心法)：
  - ✓ 在DAG中进行反向解析，遇到宽依赖就断开
  - ✓ 遇到窄依赖就把当前的RDD加入到Stage中
  - ✓ 将窄依赖尽量划分在同一个Stage中，可以实现流水线计算

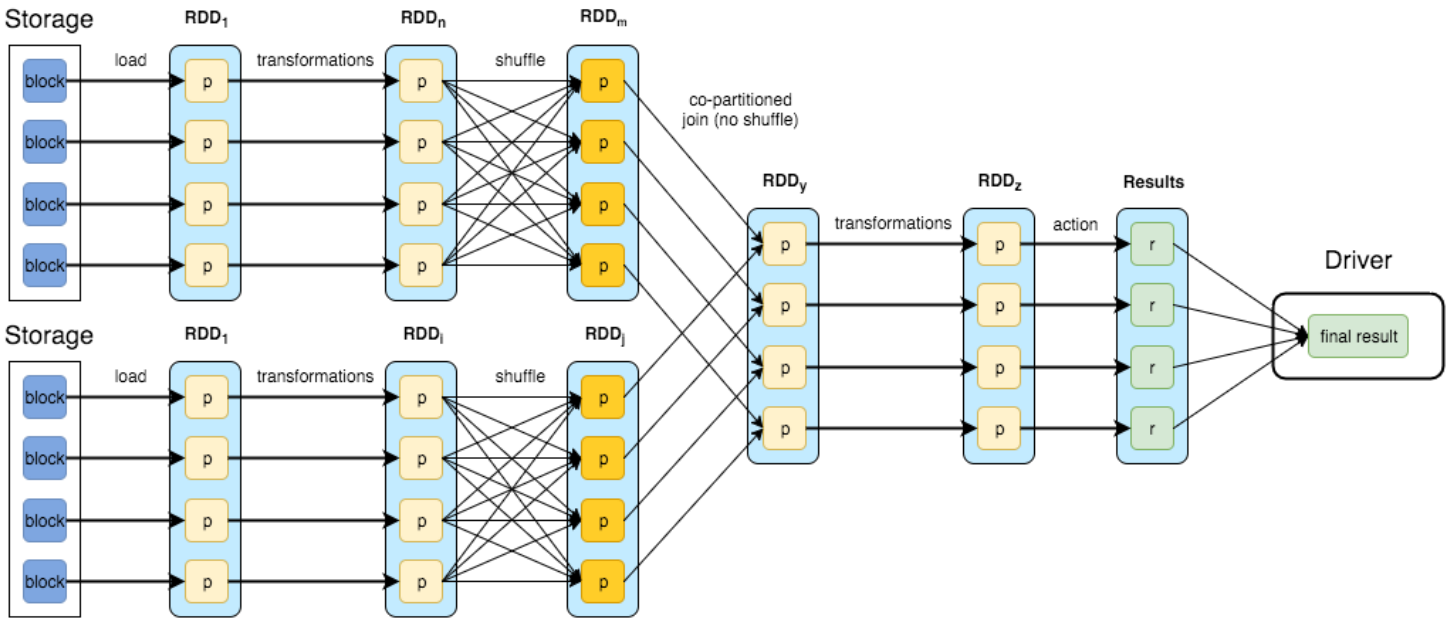

划分的实例

任务被分成三个Stage，在Stage2中，从map到union都是窄依赖，这两步操作可以形成一个流水线操作

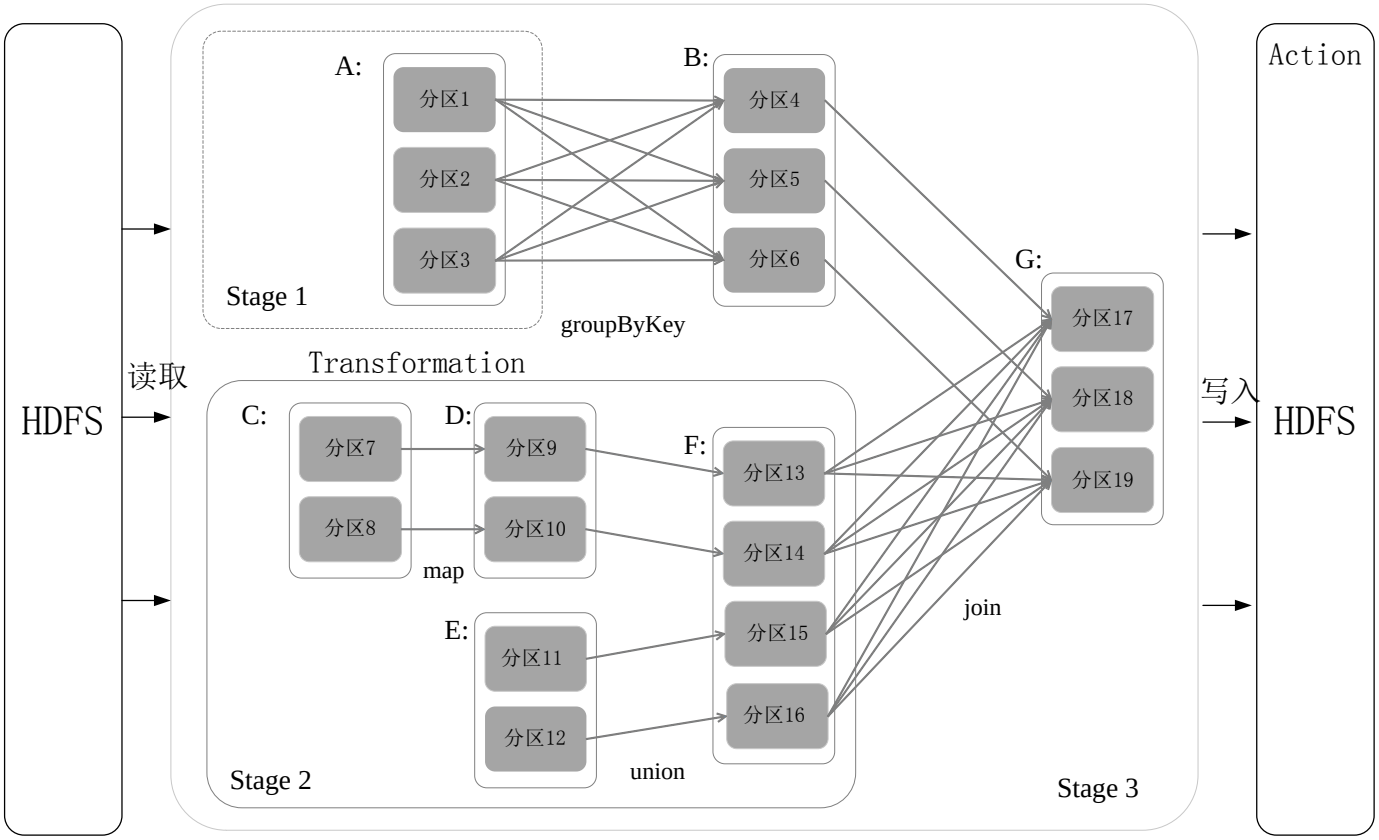

流水线操作实例

分区7通过map操作生成的分区9，可以不用等待分区8到分区10这个map操作的计算结束，而是继续进行union操作，得到分区13，这样流水线执行大大提高了计算的效率

Hyracks

Hyracks中的Jobs

- Job是Hyracks客户端提交的操作单位
- Job是operator(操作)和connector(连接)的有向无环数据流
  - operator使用/产生数据块
  - connector在operator之间再分配/传递数据

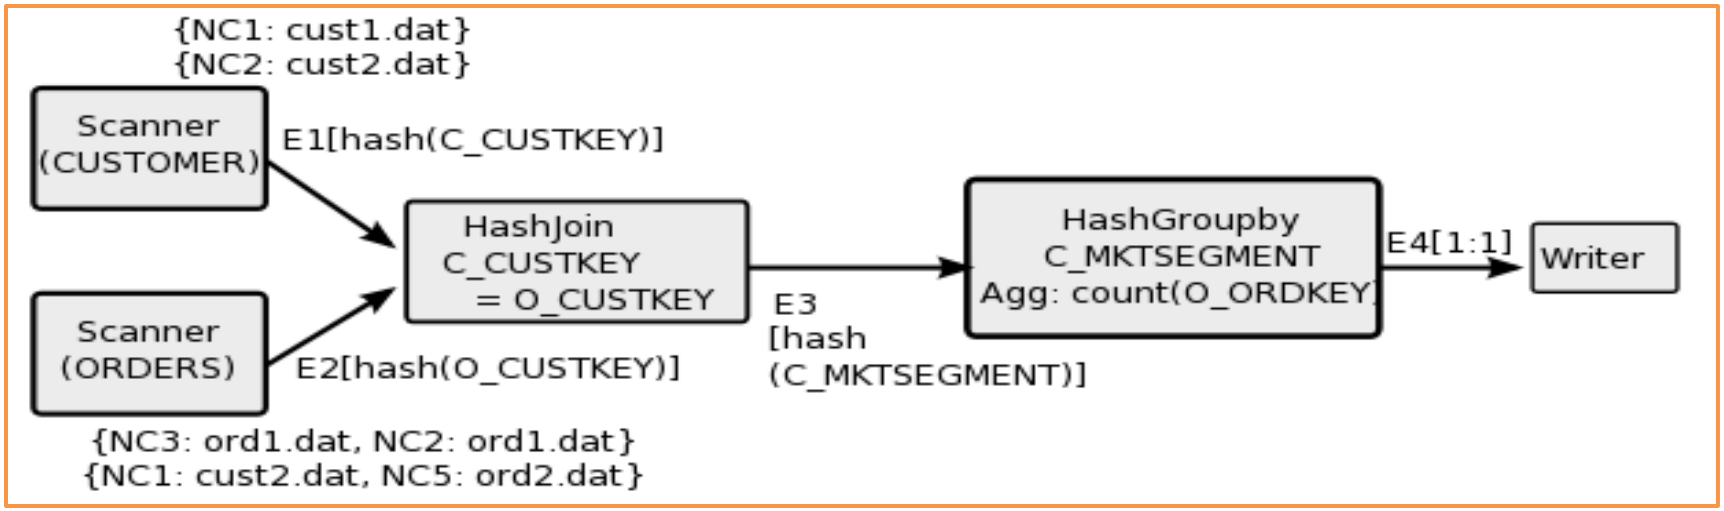

Hyracks：Operator的活动

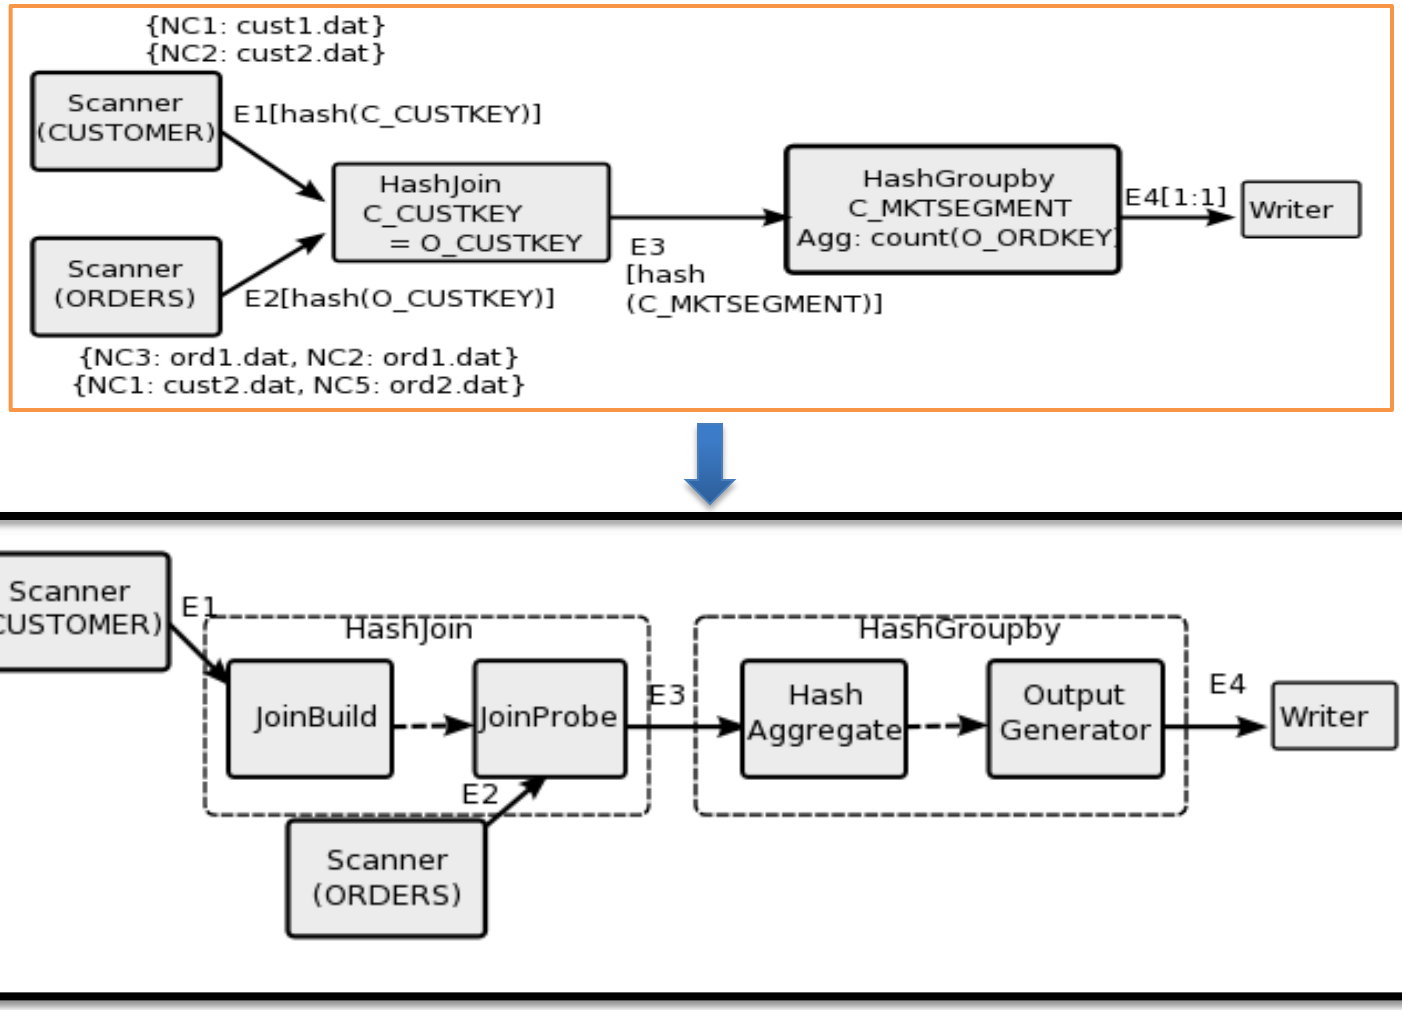

Hyracks实现MapReduce

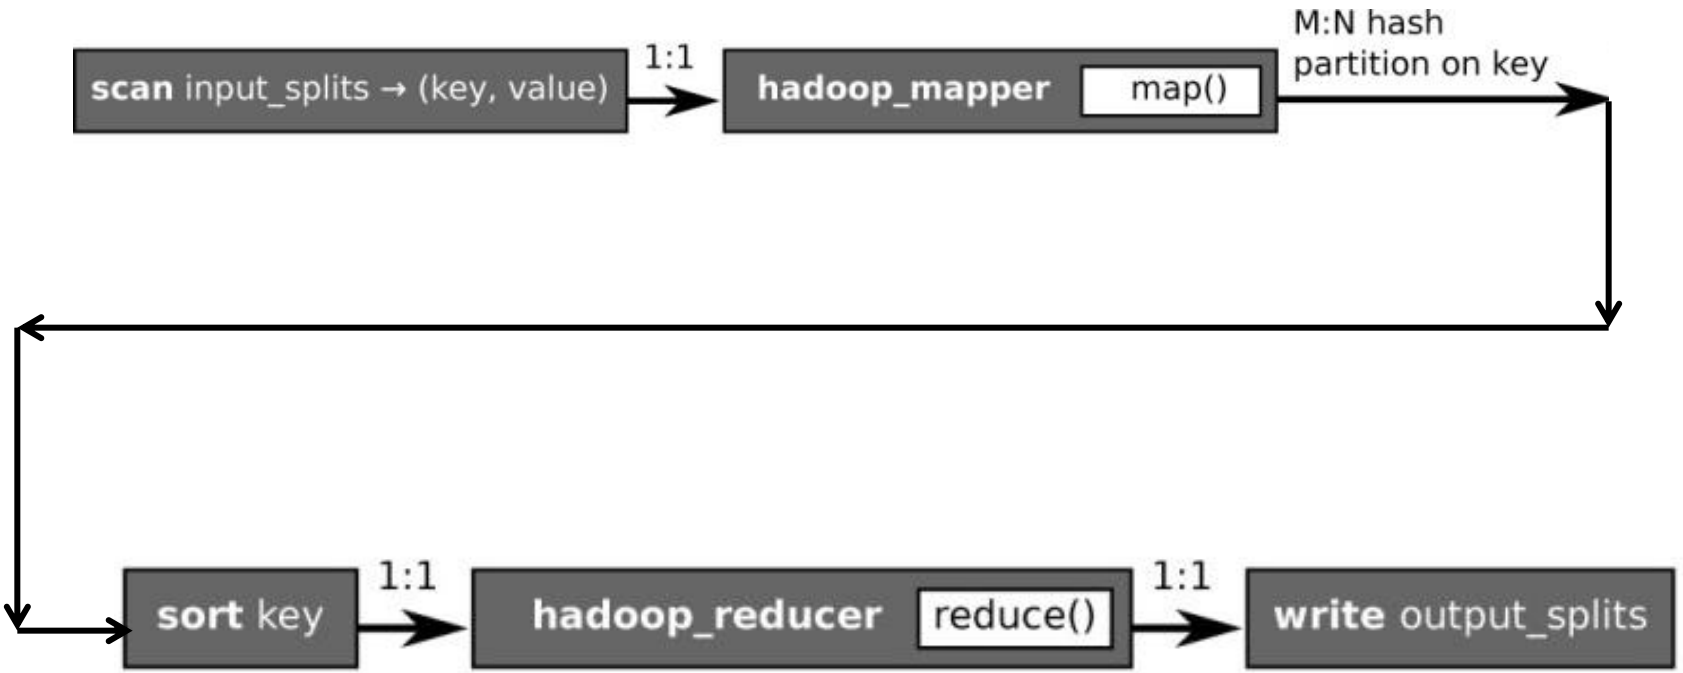

大数据的批处理系统中的流程调度

需要解决的问题

- 执行过程中如何执行操作？

需要考虑的问题

- 可扩展性高
- 效率高


Spark
Lightning-fast cluster computing

Spark端到端流程

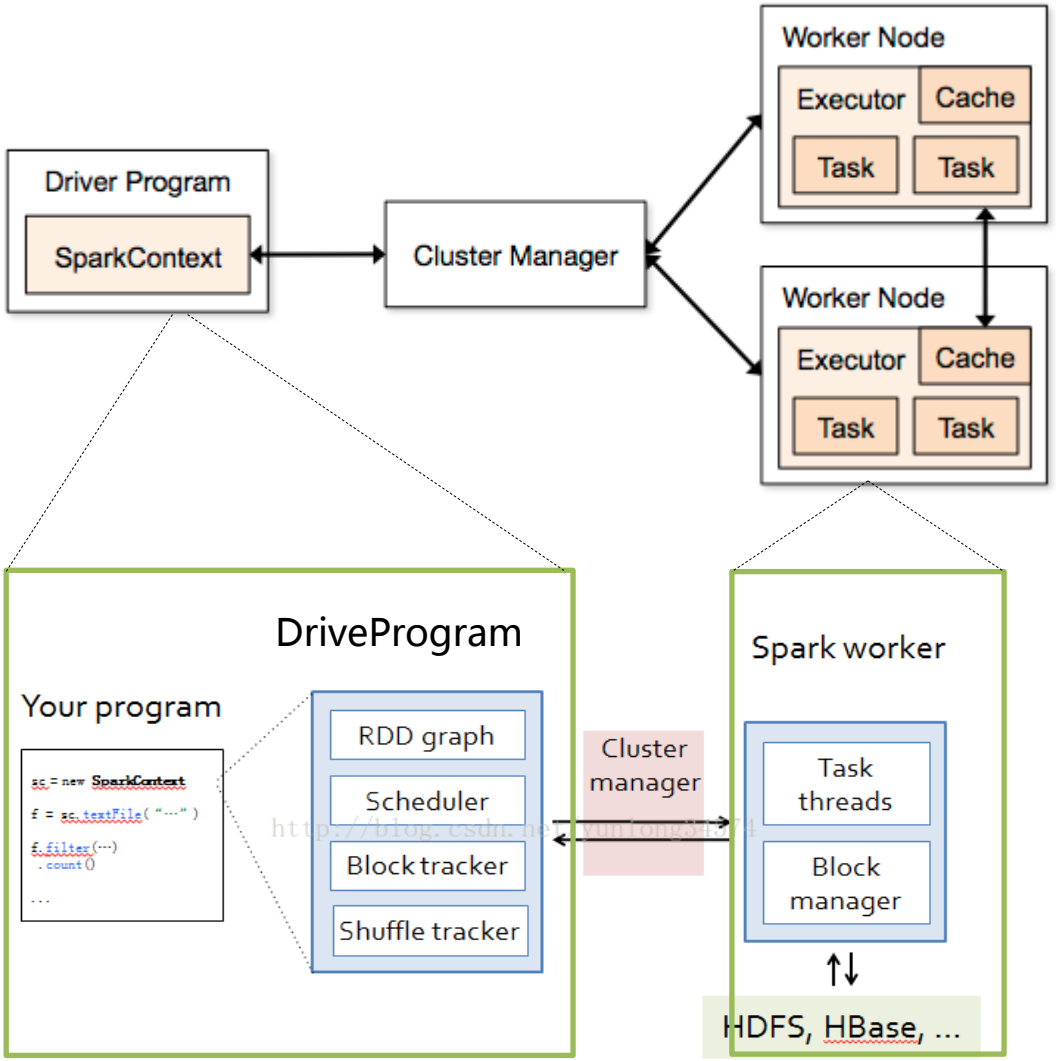

整体流程

- Spark的Driver Program (简称Driver)包含用户的应用程序
- Driver完成task的解析和生成
- Driver向Cluster Manager（集群资源管理器）申请运行task需要的资源。
- 集群资源管理器为task分配满足要求的节点，并在节点按照要求创建Executor
- 创建的Executor向Driver注册。
- Driver将spark应用程序的代码和文件传送给分配的executor
- executor运行task，运行完之后将结果返回给Driver或者写入HDFS或其他介质。

RDD运行过程

（1）创建RDD对象；
（2）SparkContext负责计算RDD之间的依赖关系，构建DAG；
（3）DAGScheduler负责把DAG图分解成多个Stage，每个Stage中包含了多个Task，每个Task会被TaskScheduler分发给各个WorkerNode上的Executor去执行。

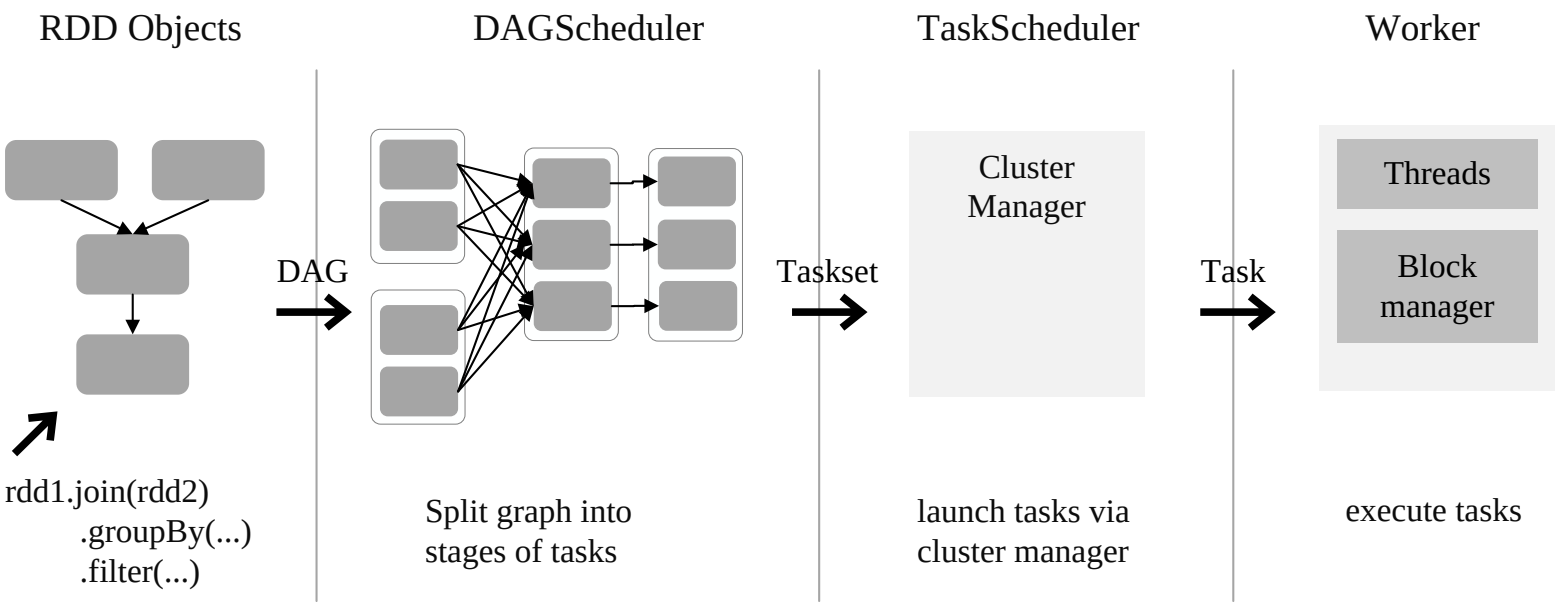

综合案例

本地文件word.txt包含很多行文本，每行文本由多个单词构成，单词之间用空格分隔。可以使用如下语句进行词频统计（即统计每个单词出现的次数）：

```
scala> val  lines = sc.  //代码一行放不下，可以在圆点后回车，在下行继续输入
|  textFile("file:///usr/local/spark/mycode/wordcount/word.txt")
scala> val wordCount = lines.flatMap(line => line.split(" ")).
|  map(word => (word, 1)).reduceByKey((a, b) => a + b)
scala> wordCount.collect()
scala> wordCount.foreach(println)
```

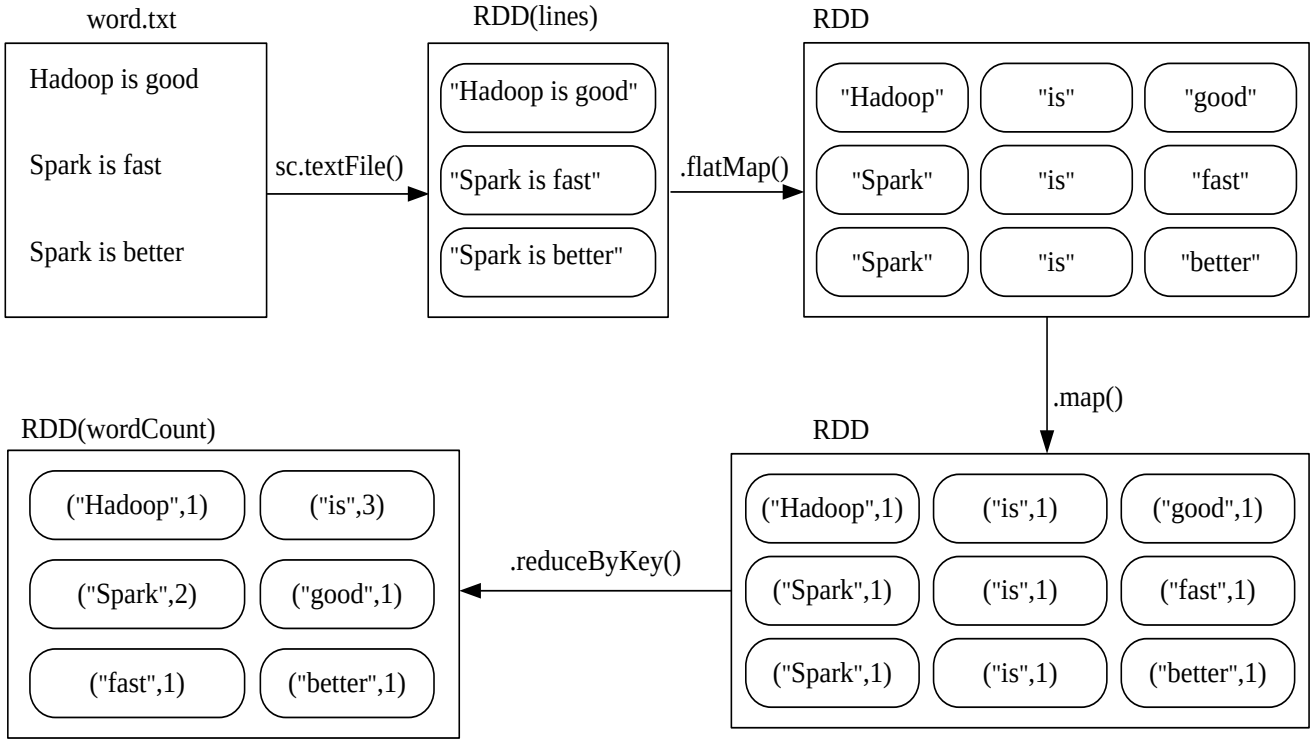

集群执行过程

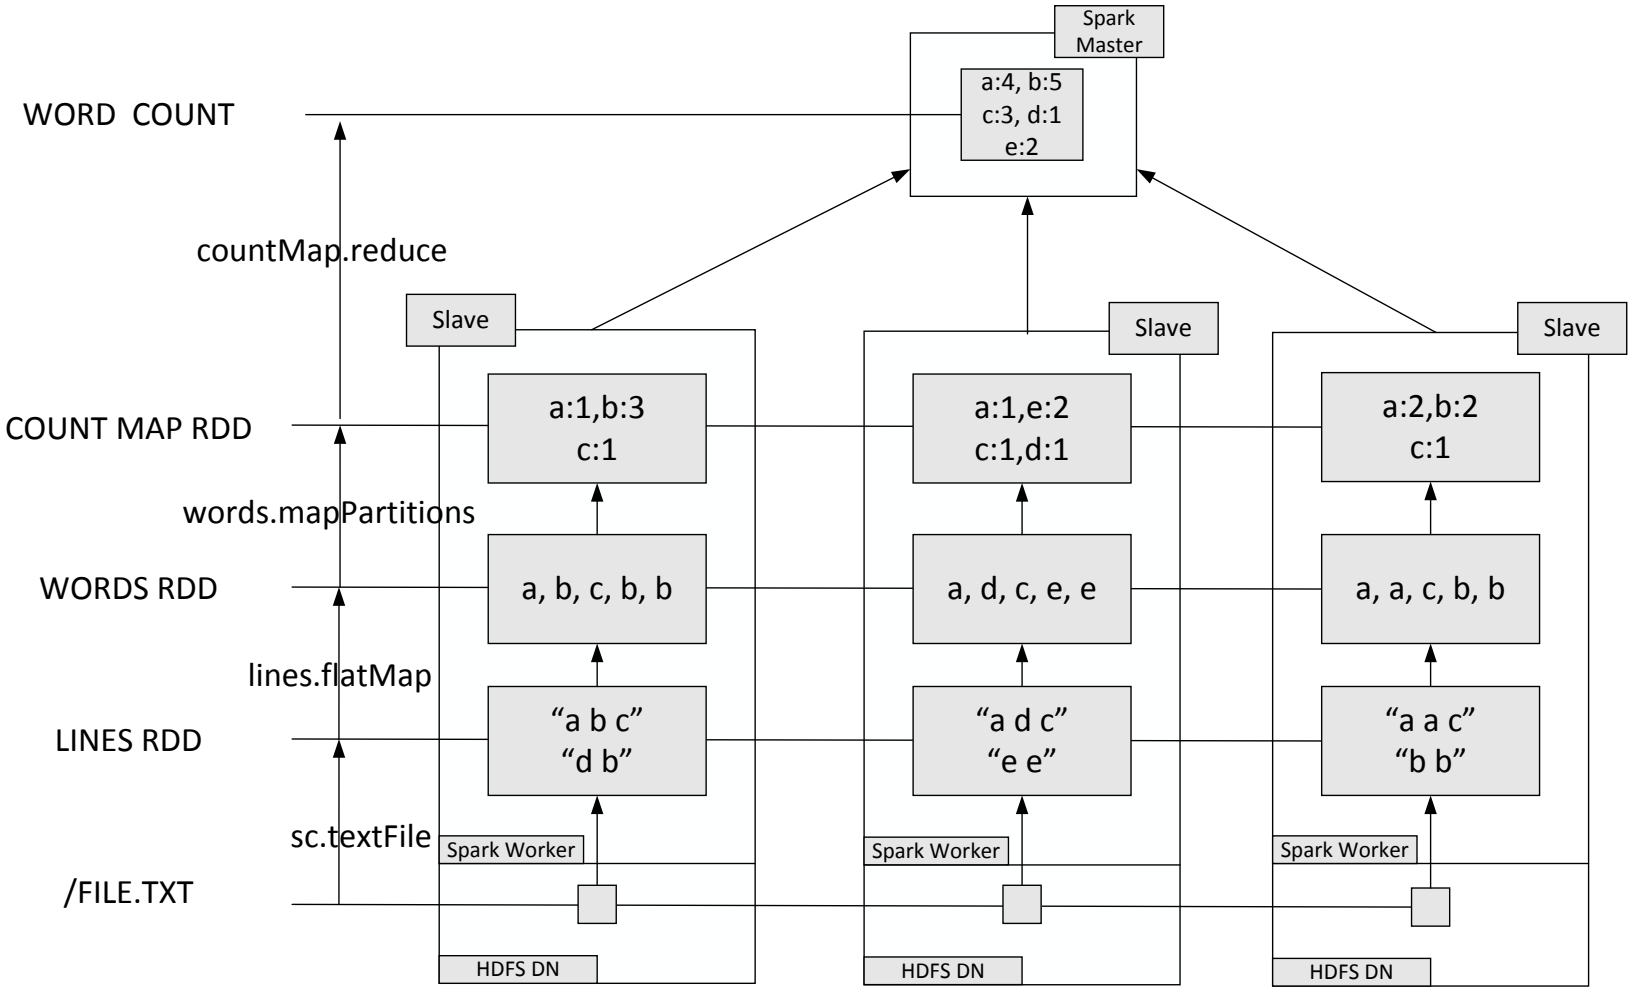
Spark Master
a:4, b:5
c:3, d:1
e:2
WORD COUNT
countMap.reduce
Slave
Slave
Slave
COUNT MAP RDD
a:1,b:3
c:1
a:1,e:2
c:1,d:1
a:2,b:2
c:1
words.mapPartitions
WORDS RDD
a, b, c, b, b
a, d, c, e, e
a, a, c, b, b
lines.flatMap
LINES RDD
“a b c”
“d b”
“a d c”
“e e”
“a a c”
“b b”
sc.textFile
/FILE.TXT
Spark Worker
Spark Worker
Spark Worker
HDFS DN
HDFS DN
HDFS DN

Hyracks

并行执行的实例

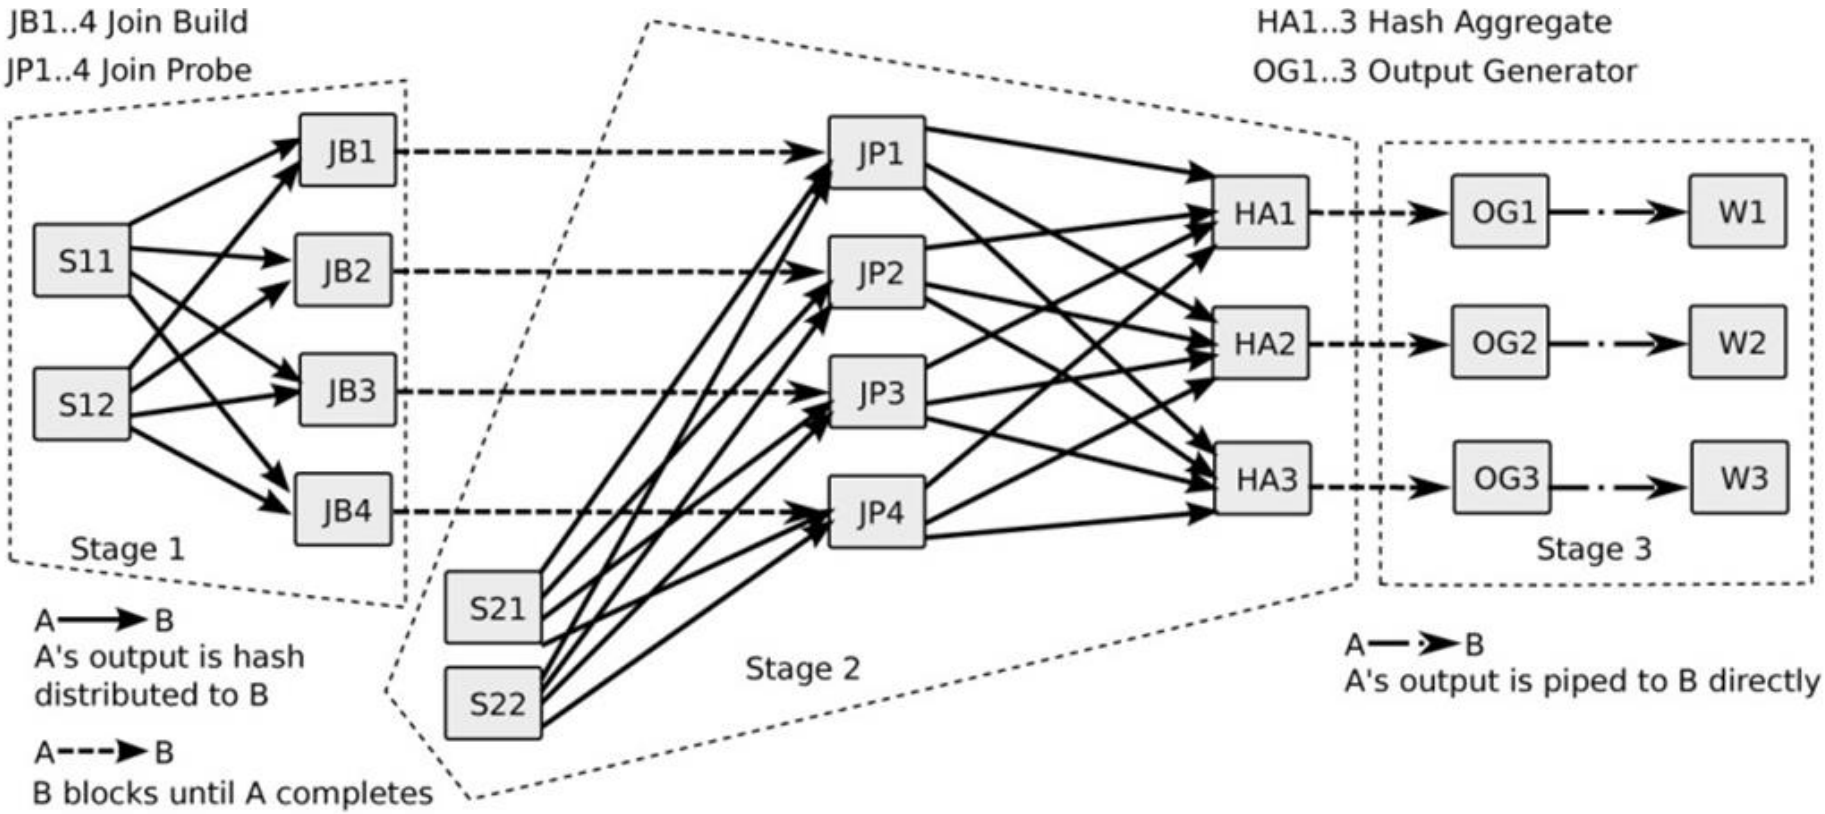
JB1..4 Join Build
JP1..4 Join Probe
HA1..3 Hash Aggregate
OG1..3 Output Generator
S11
S12
JB1
JB2
JB3
JB4
Stage 1
S21
S22
JP1
JP2
JP3
JP4
Stage 2
HA1
HA2
HA3
OG1
OG2
OG3
W1
W2
W3
Stage 3
A ⟶ B
A's output is hash distributed to B
A ⇢ B
B blocks until A completes
A ⟶ B
A's output is piped to B directly

并行执行的实例

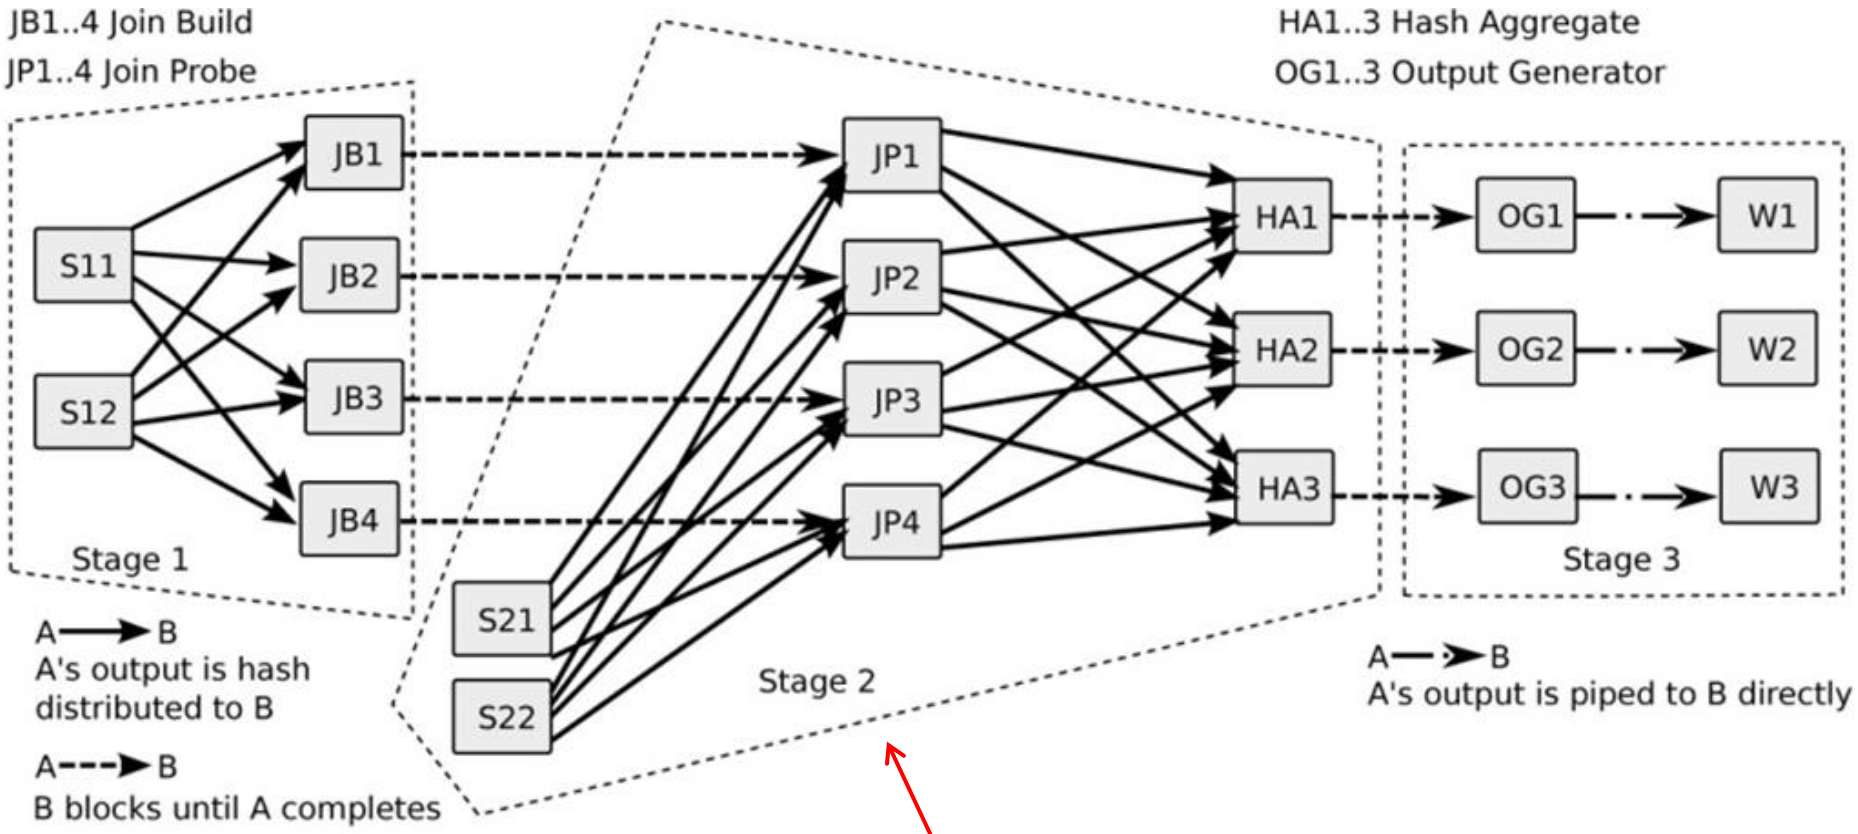

阶段2
(输入阶段完成后启动)

大数据的批处理系统中的事务处理

需要解决的问题

如何保证执行的正确性

需要考虑的问题

- 结点出错怎么办？
- 分布式系统出现读脏写脏怎么办？


Spark
Lightning-fast cluster computing

RDD容错机制

- RDD维护着可以用来重建丢失分区的信息
- 例如：

```
cachedMsgs = textFile(...).filter(_.contains( “error” ))
                          .map(_.split( ‘\t’ )(2))
                          .cache()
```

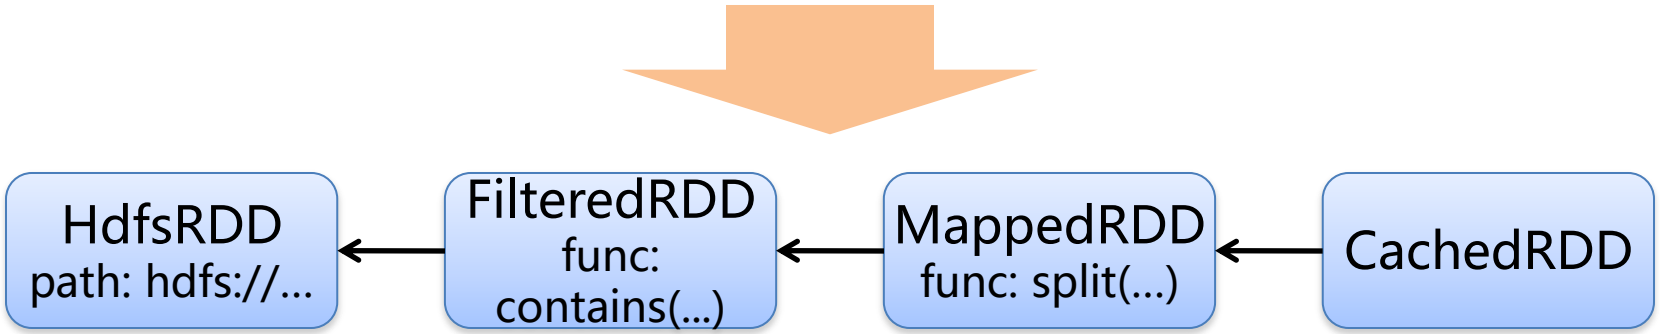

Hyracks

Hyracks 容错: 可否继续工作?

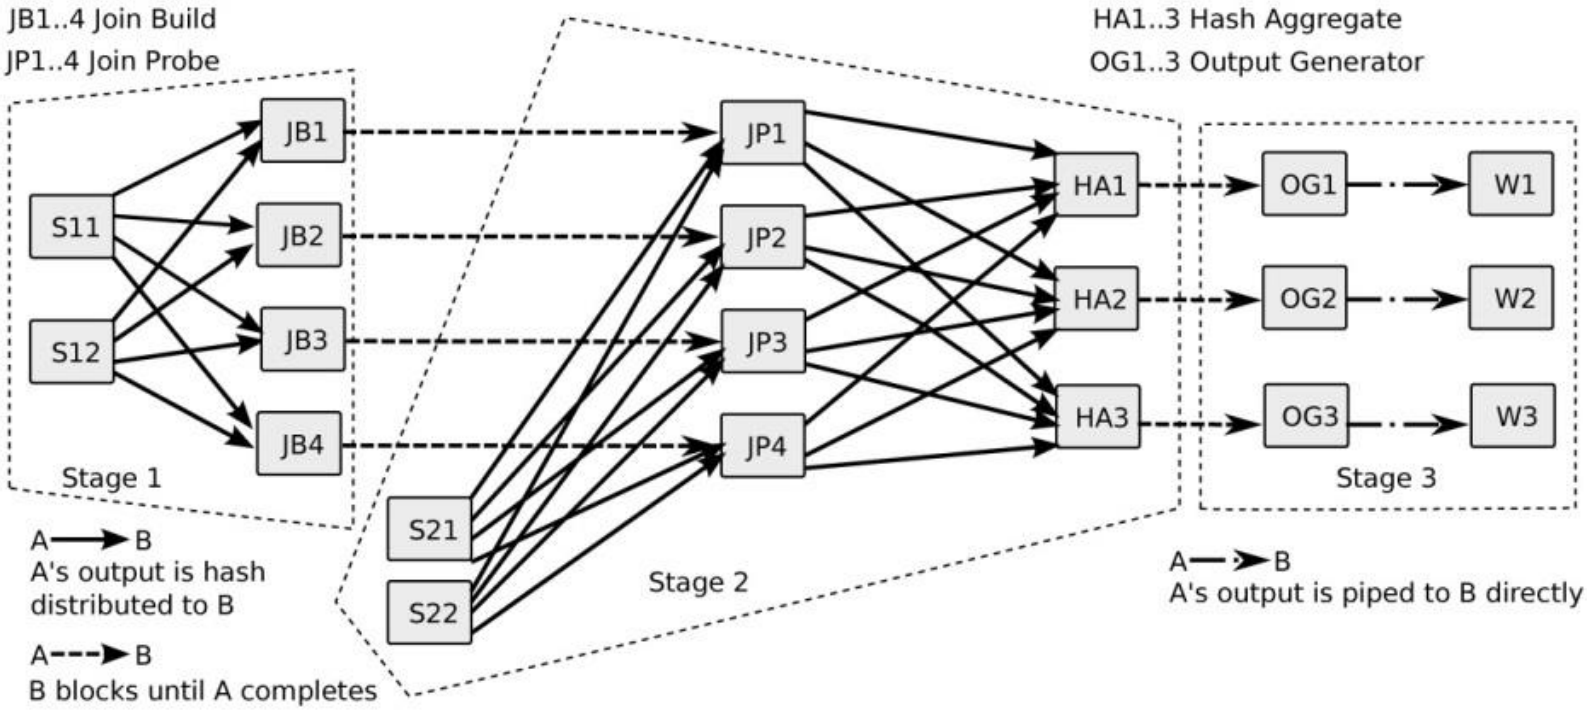

Hyracks 容错: 可否继续工作?

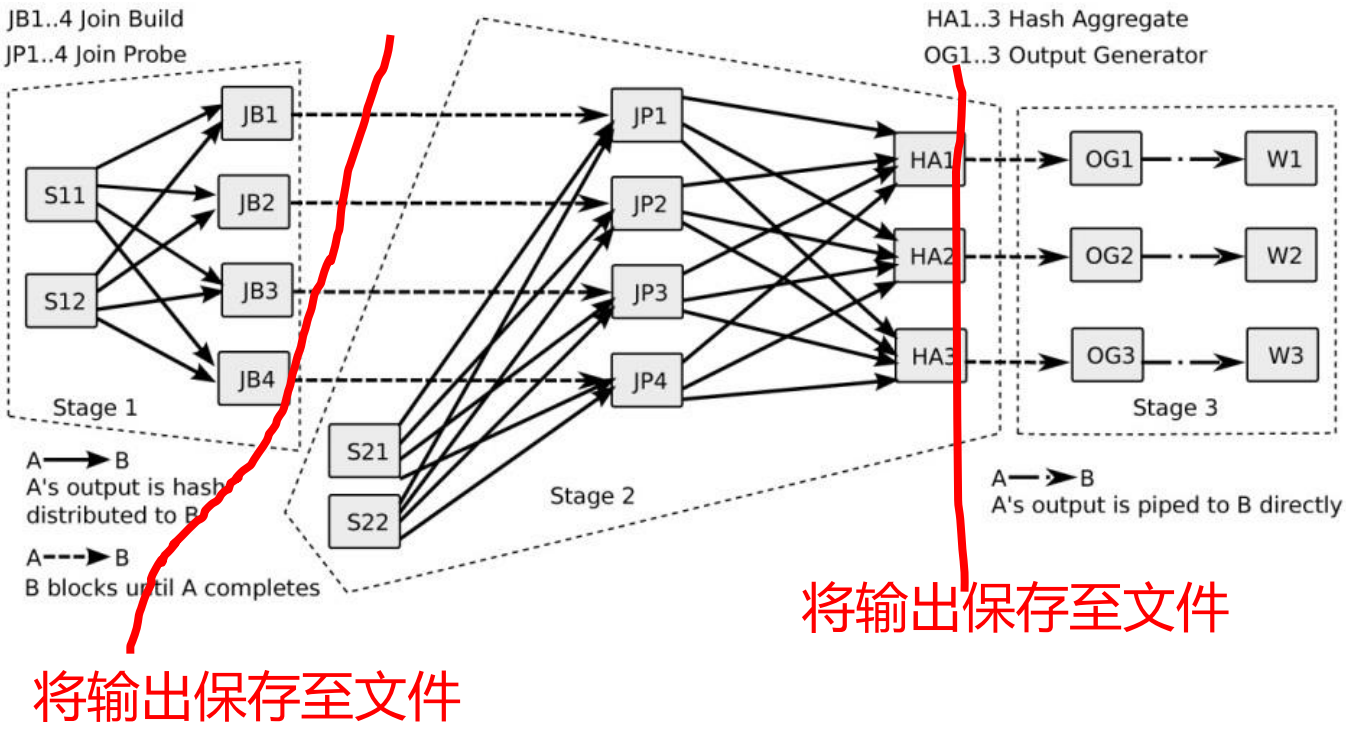

Hadoop/MR 方法: 保存部分结果永久存储;失败后，重做所有的工作来重建丢失的数据

Hyracks 容错: 可否继续工作?

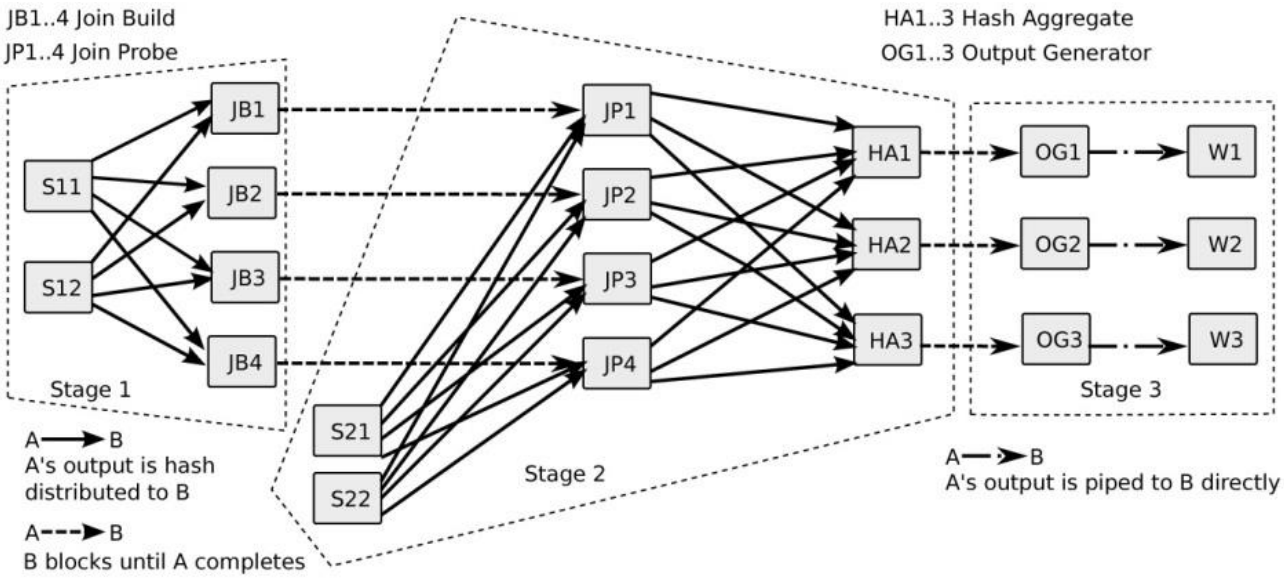

我们可以做的更好吗?
每个进程保留以前的结果，直到不再需要

Pi 输出: r1, ~~r2, r3, r4~~, r5, r6, r7, r8

已经找到到最终结果的路径

当前输出

大数据的批处理系统中的数据存储机制

需要解决的问题

- 何时存储数据？
- 数据存储成什么形式？

需要考虑的问题

- 高(时间/存储)效率
- 内存满足要求


Spark
Lightning-fast cluster computing

Spark中的存储机制

- RDD缓存：包括基于内存和磁盘的缓存
  - ✓ 分区和数据块是一一对应的
  - ✓ 在内部建立RDD分区和数据块之间的映射，需要读取缓存的RDD时，根据映射关系取得分区对应的数据块
  - ✓ 内存缓存=哈希表+存取策略
  - ✓ 一个数据块对应着文件系统中的一个文件，文件名和块名称的映射关系是通过哈希算法计算所得的
- Shuffle数据的持久化
  - Shuffle数据块必须是在磁盘上进行缓存的
  - Shuffle数据块的存储有两种方式：
    - 将Shuffle数据块映射成文件
    - 将Shuffle数据块映射成文件中的一段

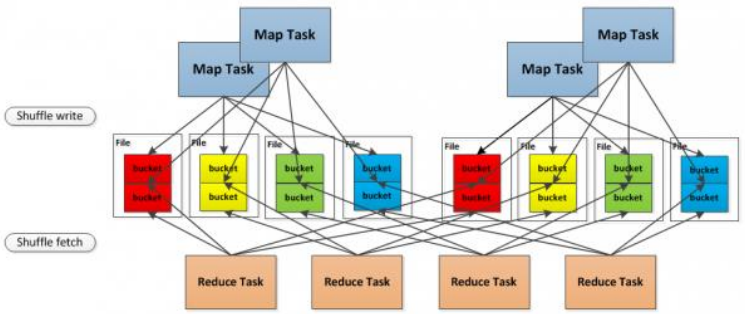

Hyracks

Hyracks中的存储机制

Database